Localização, localização, localização: um modelo de fundação tabular precisa de atributos espaciais?

O TabPFN-3.5 contra a econometria espacial e o *gradient boosting* em 130.000 preços de transação declarados em São Paulo

Agnaldo Calvi Benvenho*

Outubro de 2026

Resumo

Os modelos de avaliação em massa codificam explicitamente a dependência do preço em relação à localização, por meio de matrizes de pesos espaciais, defasagens espaciais, modelos locais geograficamente ponderados ou atributos de vizinhança construídos à mão. Este trabalho pergunta se um modelo de fundação tabular pode dispensar tudo isso. O TabPFN-3.5 recebe os atributos do imóvel e as coordenadas geográficas como duas colunas numéricas comuns, sem nenhuma modelagem espacial, e é comparado com um modelo hedônico por OLS, um modelo autorregressivo espacial de defasagem (SAR, estimação GM), um XGBoost com defasagem espacial de k vizinhos mais próximos, coordenadas rotacionadas e ajuste aninhado, e um XGBoost geograficamente ponderado. Os dados são 82.187 preços de transação declarados do imposto de transmissão de São Paulo (ITBI) em 2025 e 47.810 nos sete primeiros meses de 2026, para apartamentos, casas e unidades comerciais. A avaliação tem duas pernas: validação cruzada deixando de fora um dos dez blocos espaciais por vez, e um teste fora do tempo que ajusta em 2025 e prevê 2026. Os critérios de refutação foram fixados antes das rodadas: erro agregado pior, derrotas na maioria dos blocos sob testes pareados, ou mais autocorrelação espacial residual (I de Moran) que a deixada pelas *baselines* explicitamente espaciais. Fora do tempo, o modelo de tabela crua vence os três especialistas espaciais em ao menos 9 dos 10 blocos (RMSE de 0,265 no logaritmo do valor unitário contra 0,283–0,326; MAPE de 19,5% contra 20,9–25,0%) e deixa a menor autocorrelação residual entre os modelos comparados ($I = 0{,}092$); com o CEP bruto no lugar das coordenadas — uma coluna de texto, nenhuma geometria — todos esses vereditos se mantêm. Nos blocos nunca vistos, empata com as duas variantes de XGBoost no erro e vence o SAR, mas deixa mais estrutura espacial nos resíduos ($I = 0{,}348$ contra 0,309–0,326): refutação parcial, registrada. O SHAP por permutação mostra as duas coordenadas como os insumos mais fortes do modelo; o resultado do CEP mostra que, dentro de um mercado observado, o que elas carregam é a localização como identificador, e não geometria, e que só coordenadas extrapolam para distritos sem vendas. Para a avaliação em massa dentro de um mercado com histórico de vendas, o modelo de fundação com a tabela crua é o preditor mais forte desta comparação, com um único ajuste de quinze segundos e nenhuma engenharia espacial.

Palavras-chave: avaliação em massa; modelos de fundação tabulares; TabPFN; autorregressão espacial; validação cruzada espacial; preços hedônicos; São Paulo.

1 Introdução

A avaliação em massa na escala da cidade apoia-se na leitura hedônica do mercado imobiliário [21]: o preço de um bem heterogêneo é função de seus atributos, e a localização é o atributo

*IBAPE Nacional (Instituto Brasileiro de Avaliações e Perícias de Engenharia) e Universidade Presbiteriana Mackenzie, São Paulo, Brasil. agnaldo.benvenho@gmail.com. Código e dados: `https://github.com/abenvenho/tabpfn-itbi-sp`.

que domina os demais — coisas próximas são mais relacionadas que coisas distantes [23]. Os preços de imóveis vizinhos não são, portanto, observações independentes, o que fere a hipótese por trás da regressão por mínimos quadrados ordinários em que a prática de avaliação se apoia [2]. As respostas consagradas modelam a dependência de forma explícita: uma matriz de pesos espaciais e um termo autorregressivo na econometria espacial [2, 12], modelos locais reajustados ao longo do mapa na regressão geograficamente ponderada [7] e em seus descendentes baseados em árvores [8], ou atributos de vizinhança alimentados à mão a um *gradient boosting*. Tudo isso funciona — e tudo isso é engenharia que precisa ser refeita para cada cidade e cada base: uma matriz de pesos a construir, uma banda a calibrar, uma defasagem a recalcular dentro de cada dobra de treino.

Os modelos de fundação para dados tabulares oferecem outro contrato. O TabPFN é um *transformer* [24] pré-treinado em milhões de tarefas tabulares sintéticas; no uso, realiza aprendizado em contexto: toma a tabela de treino inteira como entrada e prevê as linhas de teste em uma única passagem, sem passos de gradiente e sem ajuste [9, 10]. A terceira geração estendeu a abordagem a tabelas grandes e à regressão [17], e a versão 3.5 lê nativamente colunas categóricas de alta cardinalidade e texto livre [18]. Se um modelo assim, recebendo latitude e longitude como duas colunas numéricas simples, aprende a dependência espacial que os especialistas codificam por construção é uma pergunta empírica em aberto — e prática, porque, se aprende, a maquinaria espacial acima se torna opcional para uma classe ampla de problemas de avaliação.

A pergunta tem origem concreta. Em um estudo comparativo sobre 5.005 ofertas de apartamentos em Belo Horizonte, o TabPFN v3 com coordenadas cruas superou OLS, SAR, SEM e um modelo semiparamétrico de defasagem espacial sob validação cruzada por blocos espaciais [3]. Aquele resultado pedia um teste mais duro, e este artigo é esse teste: preços de transação declarados em vez de ofertas, três tipologias em vez de uma, 82.187 linhas de treino em vez de 5.005, uma perna de um ano à frente somada à validação por blocos, um critério de autocorrelação residual capaz de refutar a tese mesmo onde o erro não refuta, e um conjunto mais forte de oponentes espaciais. O enquadramento é falsificacionista: a hipótese é enunciada antes das rodadas, com os critérios que a refutariam, e a comparação é deliberadamente assimétrica *contra* ela — as *baselines* mantêm todas as vantagens espaciais, o modelo de fundação recebe a tabela crua.

A hipótese é enunciada de modo que possa falhar:

> Um modelo de fundação tabular que recebe apenas os atributos do imóvel e as coordenadas como duas colunas numéricas simples — sem matriz de pesos espaciais, sem defasagem espacial, sem atributos de vizinhança construídos à mão — prevê preços espacialmente correlacionados tão bem quanto, ou melhor que, modelos especializados que codificam a dependência espacial explicitamente.

Ela é refutada se qualquer um dos itens a seguir valer sob um protocolo comum: RMSE ou MAPE agregados piores; derrotas na maioria dos blocos espaciais sob testes pareados; ou mais autocorrelação espacial deixada nos resíduos fora da amostra do que a deixada pelos modelos explicitamente espaciais.

O artigo contribui com: (i) uma comparação de um modelo de fundação tabular com *baselines* de econometria espacial e de árvores espacialmente aumentadas — entre elas um XGBoost geograficamente ponderado — sobre preços declarados na escala da cidade; (ii) um protocolo de duas pernas, validação cruzada por blocos espaciais mais teste fora do tempo, com critérios de refutação pré-registrados que incluem a autocorrelação espacial residual; (iii) ablações que isolam o que carrega a localização dentro do modelo, substituindo as coordenadas por um CEP bruto e acrescentando o texto livre do formulário do imposto; (iv) um *pipeline* público e reproduzível sobre dados municipais abertos; e (v) o próprio achado, refutação parcial incluída.

2 Trabalhos relacionados

Modelos hedônicos espaciais. O arcabouço hedônico [21] combinado com a primeira lei de Tobler [23] leva à família da econometria espacial: os modelos de defasagem espacial (SAR) e de erro espacial, estimados por máxima verossimilhança ou pelo procedimento de momentos generalizados de Kelejian and Prucha [11], com a matriz de pesos como portadora da estrutura de vizinhança [2, 12]. A regressão geograficamente ponderada abandona o vetor global de coeficientes e reajusta um modelo local em cada ponto de calibração, com pesos decrescentes na distância [7].

Aprendizado de máquina com atributos espaciais. Os conjuntos de árvores não enxergam o espaço, a menos que ele lhes seja servido. Os dispositivos usuais são a defasagem espacial da resposta calculada sobre os vizinhos de treino, transformações de coordenadas como eixos oblíquos ou rotacionados [15] e covariáveis de distância. O Geographical-XGBoost [8] transplanta a ideia geograficamente ponderada para o *gradient boosting*: um XGBoost local por ponto de calibração, combinado com um modelo global. Avaliar qualquer dessas alternativas com honestidade exige validação cruzada espacial, pois partições aleatórias deixam vizinhos do ponto de teste dentro do conjunto de treino [14, 20].

Modelos de fundação tabulares, e o espaço dentro deles. O TabPFN [9, 10] e sua terceira geração [17, 18] substituem o treinamento por base de dados pelo aprendizado em contexto sobre *priors* sintéticos. Duas linhas recentes levam o espaço *para dentro* do modelo: o TabPFN-GSA modifica a arquitetura com atenção esparsa geoespacial [6], e a *Kriging-prior Regression* alimenta o TabPFN com atributos derivados de krigagem [22]. Este artigo toma a posição oposta: o modelo tal como distribuído, sem alteração de arquitetura e sem atributo espacial, com a dependência deixada para o aprendiz em contexto encontrar em duas colunas cruas.

TabPFN na avaliação de imóveis. Até onde o autor conhece, as únicas aplicações publicadas do TabPFN à avaliação de imóveis são as suas próprias, ambas em português. Sobre preços de transação do ITBI de São Paulo, o TabPFN v2 superou um FT-Transformer e a regressão linear múltipla [4]; sobre as ofertas de Belo Horizonte, o TabPFN v3 superou os modelos econométricos espaciais, lineares e não lineares, da comparação [3]. Em relação a este último, o presente estudo muda a resposta (preços declarados em vez de ofertas), o escopo (três tipologias em vez de apenas apartamentos), a escala (82.187 linhas de treino em vez de 5.005), o protocolo (acrescenta a perna fora do tempo e o critério de autocorrelação residual) e os oponentes (um XGBoost espacialmente aumentado e um XGBoost geograficamente ponderado somam-se às *baselines* econométricas).

3 Dados

3.1 Fonte e saneamento

A Prefeitura de São Paulo publica todas as guias pagas do imposto de transmissão de bens imóveis (ITBI) com o preço de transação declarado, a chave cadastral (SQL: setor, quadra, lote) e os atributos físicos do imóvel vindos do cadastro do IPTU: áreas construída e de terreno, uso, padrão construtivo e o ano de construção corrigido (ACC). O arquivo de 2025 contém 230.525 guias e o de janeiro–julho de 2026, 135.655. As coordenadas vêm dos centroides dos polígonos de quadra fiscal do cadastro municipal (GeoSampa), de modo que todos os imóveis de uma mesma quadra compartilham a localização; a distância à estação de metrô ou trem mais próxima é calculada a partir dos 203 pontos de estação do mesmo portal.

A Tabela 1 apresenta a cadeia de saneamento com a contagem de registros após cada passo; o relatório completo, aberto por tipologia, está versionado com os dados

Tabela 1: A cadeia de saneamento: registros remanescentes após cada passo.

#	Passo	2025	2026 (jan–jul)
0	Base bruta (todas as guias pagas de ITBI)	230.525	135.655
1	Natureza da transação contém "compra e venda"	207.518	124.289
2	Proporção transmitida = 100%	108.750	61.304
3	Situação cadastral ativa	108.420	61.112
4	SQL válido de 11 dígitos e data válida	108.420	61.112
5	Tipologia mantida (apartamento / casa / comercial)	90.927	51.919
6	Área construída (de referência) > 0	90.927	51.919
7	ACC plausível ($1900 \leq$ ACC $\leq$ ano da transação)	90.927	51.918
8	Deduplicação em (chave, data, preço)	90.673	51.810
9	Preço declarado $\geq$ R$ 10.000	89.078	51.202
10	Razão preço / valor venal de referência (VVR) em [0,3; 5]	87.488	50.430
11	Subdeclaração: excluídas as compras à vista coladas no VVR	84.263	48.879
12	Cercas de Tukey (1,5 IQR) em ln(R$/m^2), por tipo (cercas de 2025)	82.193	47.814
13	Junção ao centroide da quadra fiscal (99,99%)	82.187	47.810

(`data/filter_report.md`). As bases limpas contêm 82.187 transações de 2025 (treino) e 47.810 de 2026 (teste). Uma amostra estratificada de 24.000 linhas de 2025 (12.000 apartamentos, 7.000 casas, 5.000 unidades comerciais; "Nível A") é usada onde as *baselines* mais lentas precisam rodar.

3.2 Subdeclaração

A base de cálculo do ITBI é max(preço declarado, valor venal de referência), de modo que quem subdeclara não tem incentivo a declarar abaixo do valor de referência: as compras à vista subdeclaradas acumulam-se exatamente sobre ele. O diagnóstico encontrou esse acúmulo concentrado nas compras à vista, e o *pipeline* remove as transações à vista declaradas a menos de 1% do valor de referência: 3.225 guias em 2025 e 1.551 em 2026 (passo 11 da Tabela 1; o quadro residual após a exclusão está em `data/underdeclaration_report.md`). As transações financiadas passam pela análise do credor e são mantidas; a Seção 5.3 repete toda a análise apenas sobre elas.

3.3 Estatísticas descritivas

Tabela 2: As três bases. Valor unitário (VU) = preço declarado / área construída, em R$/m^2; a última coluna é a sua mediana.

Base	Linhas	Apart.	Casas	Comercial	Financ.	Mediana do VU
2025, completa (treino)	82.187	60.067	15.940	6.180	34%	4.836
2025, Nível A (amostra)	24.000	12.000	7.000	5.000	30%	4.715
2026, jan–jul (teste)	47.810	35.354	9.429	3.027	42%	4.970

A resposta é fortemente autocorrelacionada no espaço, como são os preços urbanos. O I de Moran do logaritmo bruto do valor unitário, na matriz k-NN-8 usada em todo o artigo, é de 0,430 na amostra do Nível A ($z = 141{,}8$) e de 0,506 na base de 2026 ($z = 235{,}7$): o valor unitário de um imóvel está próximo do de seus vizinhos muito além do acaso, exatamente a estrutura que as *baselines* espaciais foram construídas para explorar. A Figura 1(a) mostra como os dez blocos espaciais recobrem essa estrutura sobre a cidade. Como as coordenadas são centroides de quadra fiscal, a localização é resolvida na quadra em vez do endereço — uma escolha conservadora compartilhada por todos os modelos.

4 Métodos

4.1 Resposta e atributos

A resposta é $y = \ln(\text{preço/área construída})$. O conjunto de informação é o mesmo para todos os modelos: área construída, área do terreno, idade, padrão construtivo (nível do padrão IPTU, 0–5), distância à estação mais próxima, índice do mês, tipologia, latitude e longitude. Os modelos diferem apenas no que lhes é permitido fazer com as duas últimas.

4.2 Modelos

Hedônico por OLS. Log-linear nas áreas e na distância, quadrático na idade, *dummies* de tipologia. As coordenadas não são covariáveis: este é o piso sem localização da família linear.

SAR de defasagem. $y = \rho W y + X\beta + \varepsilon$ com matriz de pesos de k vizinhos mais próximos padronizada por linha ($k = 8$), construída dentro de cada dobra de treino e estimada pelo procedimento de momentos generalizados de Kelejian and Prucha [11], como implementado em `spreg` [19]. Uma linha fora da amostra é prevista pela forma estrutural com a defasagem espacial tomada sobre seus k vizinhos *de treino* mais próximos, $\hat{y}_i = \mathbf{x}_i^\top \hat{\beta} + \hat{\rho}\, \bar{y}_{N_8(i)}$, em que $\bar{y}_{N_8(i)}$ é a média da resposta observada desses vizinhos; a forma reduzida não está disponível fora da amostra sem a vizinhança das próprias linhas de teste, de modo que nada do conjunto de teste entra na predição. Empates nas coordenadas de centroide são desfeitos por um *jitter* determinístico submétrico ($\pm$0,5 m, semente 42), necessário porque todas as transações de uma mesma quadra fiscal compartilham o centroide exato.

XGBoost com atributos espaciais. O bloco hedônico acima mais as coordenadas UTM, suas projeções em eixos rotacionados de 30°, 45° e 60° [15] e uma defasagem espacial k-NN-8 da resposta calculada dentro da dobra de treino (*leave-one-out* para as linhas de treino). Os hiperparâmetros são ajustados por Optuna aninhado (30 tentativas TPE, parada antecipada, até 3.000 rodadas), com um *leave-one-block-out* interno sobre os blocos de treino; o bloco de teste externo nunca toca o ajuste [1, 5]. Três sementes. O espaço de busca e os valores selecionados estão no Apêndice B.

XGBoost geograficamente ponderado. O Geographical-XGBoost [8] ajusta um XGBoost local por ponto de calibração com pesos bi-quadrados de distância, $w = (1 - d^2/h^2)^2$ com h a distância ao k-ésimo vizinho, combinado com um modelo global por $\hat{y} = \alpha\, \hat{y}_{\text{local}} + (1 - \alpha)\, \hat{y}_{\text{global}}$. Tal como empacotado, ele calibra um modelo local, com sua própria busca em grade, em cada linha de treino, sobre uma matriz densa de distâncias — o que um piloto de viabilidade mostrou impraticável nesta escala (Apêndice A). A implementação aqui mantém o estimador e calibra os modelos locais em 1.000 pontos de regressão — os centros de K-médias das coordenadas de treino, cerca de um por 1,5 km^2 de cidade —, como a regressão geograficamente ponderada permite [7]; uma localização de consulta é prevista pela média, com pesos inversos à distância, de seus três modelos locais mais próximos. Os modelos locais veem os atributos hedônicos e nenhuma coordenada: o espaço entra apenas pela ponderação, como no original. A banda $k \in \{50, 100, 200, 400, 800, 1600, 3200\} \times n_{\text{treino}}/24.000$ e a mistura $\alpha \in \{0;\ 0{,}25;\ 0{,}5;\ 0{,}75;\ 1\}$ são escolhidas por validação cruzada interna por blocos dentro de cada dobra externa; a grade foi ampliada para baixo, de 400 para 50, depois que as primeiras buscas escolhiam sempre o menor valor, e 50 vizinhos é adotado como piso. Três sementes.

TabPFN-3.5, tabela crua. As nove colunas cruas, com a tipologia declarada como categórica, pelo modelo hospedado (`tabpfn-client` 0.6.0, versão de modelo 3.5). *Zero-shot*, e uma variante em modo *thinking*, na qual o ajuste explora configurações por validação interna na dobra de treino

(objetivo RMSE, esforços médio e alto). Nenhuma informação espacial de qualquer natureza além das duas colunas de coordenadas. O ajuste em 24.000 linhas leva cerca de 9 s; em 82.187 linhas, 15 s. Configurações no Apêndice B; as variantes de entrada — o CEP no lugar das coordenadas, o texto livre do formulário — são apresentadas com seus resultados na Seção 5.4.

4.3 Protocolo de avaliação

Perna 1: validação cruzada por blocos espaciais. Dez blocos de K-médias sobre as coordenadas do Nível A, cada um deixado de fora por vez [14, 20]. Toda quantidade interna à dobra (matriz de pesos, defasagem espacial, ajuste, pontos de regressão) é recalculada apenas sobre os blocos de treino. A pergunta é se o modelo consegue precificar uma parte da cidade que nunca viu — o teste mais duro para um modelo que se apoia na localização.

Perna 2: fora do tempo. Um único ajuste em 2025 (Nível A e, depois, a base completa), predições para todas as 47.810 transações de 2026, de um a sete meses após a janela de treino. Nada de 2026 toca o ajuste ou a calibração. Mesma cidade, de modo que os modelos com defasagem espacial recebem vizinhos das mesmas ruas: o cenário mais favorável à modelagem espacial explícita. Verificação de vazamento: nenhuma transação (chave, data, preço) aparece nos dois anos; 0,6% das linhas de 2026 compartilham chave cadastral com o Nível A.

Métricas e testes. RMSE, MAE e R^2 na escala logarítmica, MAPE na escala de preço, resíduo médio (viés). Autocorrelação espacial residual pelo I de Moran [16] sobre a matriz k-NN-8 das coordenadas de teste. Comparações pareadas sobre os dez blocos (em 2026, cada transação é atribuída ao bloco do centroide de K-médias de 2025 mais próximo): teste de postos sinalizados de Wilcoxon exato sobre o RMSE por bloco e *bootstrap* por blocos (2.000 reamostragens de blocos) para a diferença agregada, com intervalo percentílico de 95%. Onde o modelo é estocástico, três sementes (42, 43, 44) e a faixa entre sementes; uma rodada do TabPFN (semente 42) é pareada contra cada semente do oponente estocástico.

5 Resultados

5.1 Perna 1: blocos nunca vistos

Tabela 3: Validação cruzada *leave-one-block-out* no Nível A (24.000 linhas de 2025). Métricas fora da dobra no logaritmo do valor unitário; I de Moran dos resíduos fora da dobra na matriz k-NN-8. Valores pontuais são da semente 42; as faixas entre parênteses cobrem as três sementes.

Modelo	RMSE	MAPE	R^2	I de Moran
Mediana por tipo (piso)	0,497	42,1%	−0,04	0,446
Hedônico por OLS	0,470	39,4%	0,066	0,390
SAR de defasagem, GM ($\hat{\rho} = 0{,}91$)	0,448	38,4%	0,155	0,363
XGBoost, coordenadas rotacionadas, sem defasagem	0,397	33,3%	0,334	0,355
XGBoost, coord. rotacionadas + defasagem k-NN-8	**0,385** (0,385–0,387)	32,3%	**0,376**	**0,309** (0,309–0,318)
XGBoost geograficamente ponderado	0,410 (0,407–0,410)	34,5%	0,291	0,324 (0,319–0,326)
TabPFN-3.5, tabela crua, *zero-shot*	0,394 (0,391–0,394)	32,2%	0,346	0,348 (0,342–0,348)
TabPFN-3.5, tabela crua, *thinking* (médio)	0,389	**31,7%**	0,362	0,342
TabPFN-3.5, tabela crua, *thinking* (alto)	0,388	**31,7%**	0,366	0,339

O TabPFN-3.5 *zero-shot* vence o SAR em 8 dos 10 blocos (ΔRMSE = −0,054, IC 95% [−0,100; −0,014], Wilcoxon $p = 0{,}010$; ΔMAPE = −6,2 p.p.). Contra o XGBoost com a defasagem explícita a diferença é um empate: ΔRMSE = +0,009 [−0,018; +0,034], 7 blocos vencidos, uma derrota clara no maior bloco. Contra o XGBoost geograficamente ponderado é também um empate, pendendo para o TabPFN: ΔRMSE de −0,013 a −0,016 nas três sementes daquele modelo, todos os intervalos cruzando zero, 6 ou 7 blocos vencidos. As duas variantes de XGBoost

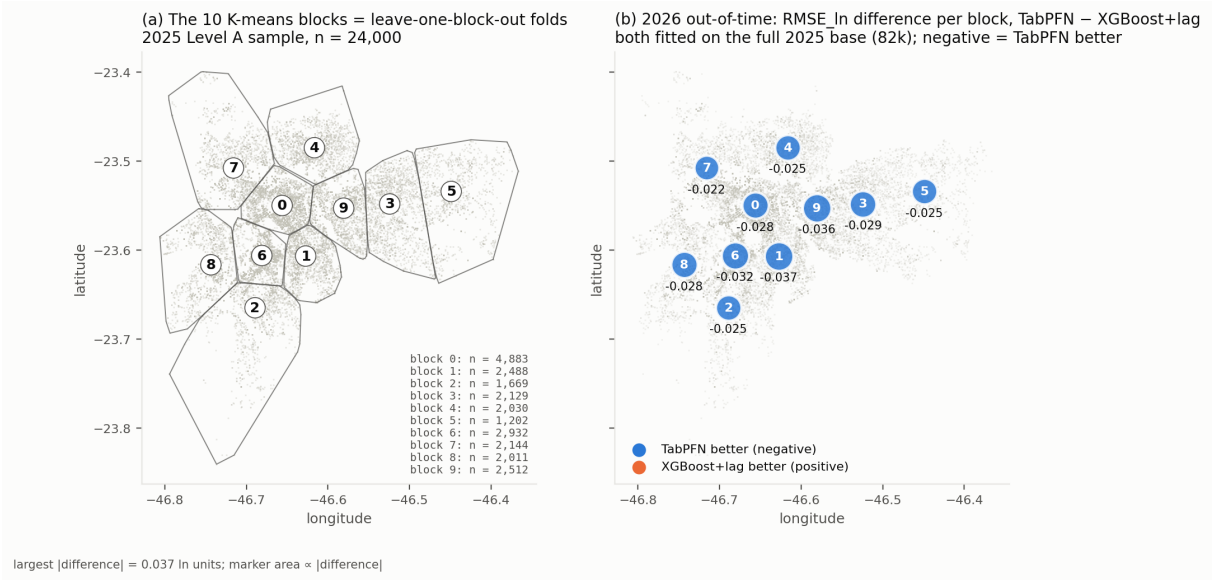


Figura 1: (a) Os dez blocos de K-médias da amostra do Nível A, cada um deixado de fora por vez. (b) Diferença de RMSE por bloco, TabPFN-3.5 − XGBoost+defasagem, no teste de 2026 com os dois modelos ajustados na base completa de 2025; negativa em todos os blocos. Os rótulos internos das figuras permanecem em inglês, comuns às duas versões do artigo.

não são intercambiáveis: a geograficamente ponderada perde para o XGBoost+defasagem por +0,023 a +0,025 (1 ou 2 blocos vencidos, $p = 0{,}027$–$0{,}037$), de modo que o XGBoost global plenamente espacial é o oponente mais duro desta perna. O modo *thinking* reduz o erro do *zero-shot* por uma margem pequena (−0,005 [−0,008; −0,001] contra a semente 42, 7 de 10 blocos, embora o Wilcoxon exato não alcance significância, $p = 0{,}105$; cerca de −0,002 contra as demais) e entrega o menor MAPE da tabela; o esforço alto custa cerca de 13 vezes mais por dobra e não acrescenta nada além de ruído.

No critério dos resíduos, a hipótese é parcialmente refutada nesta perna. O I de Moran do modelo de tabela crua (0,348) fica abaixo do SAR (0,363), mas acima das duas variantes de XGBoost: a global com defasagem explícita (0,309) e a geograficamente ponderada (0,319–0,326). Dentro do XGBoost, a defasagem sozinha vale ΔRMSE = −0,013 [−0,024; −0,004] e reduz o I residual de 0,355 para 0,309 — o valor mensurável de modelar o espaço explicitamente quando o teste é uma parte da cidade que nenhum modelo viu. A refutação é parcial e fica registrada.

Os erros são grandes em termos absolutos (R^2 de 0,29–0,38 nos modelos não lineares, contra 0,538 no estudo com ofertas): preços declarados, três tipologias e coordenadas de centroide somam ruído, e todos os modelos deixam estrutura espacial para trás nesta perna.

5.2 Perna 2: um ano à frente

Pareado sobre os dez blocos de 2026, o TabPFN-3.5 *zero-shot* treinado no Nível A vence o XGBoost com defasagem explícita em 10 de 10 (ΔRMSE = −0,013 [−0,016; −0,011], ΔMAPE = −1,4 p.p., $p = 0{,}002$), o XGBoost geograficamente ponderado em 10 de 10 (−0,038 a −0,039 nas sementes dele, todos os intervalos dentro de [−0,049; −0,028]) e o SAR por −0,071 [−0,079; −0,062]. Na base completa, a distância para o XGBoost+defasagem se amplia para −0,029 [−0,032; −0,026] (ΔMAPE = −2,0 p.p., de novo 10 de 10, e de −0,018 a −0,020 contra as duas sementes melhores dele); contra o geograficamente ponderado é −0,033 a −0,036 com 9 de 10 blocos ($p = 0{,}004$; a única derrota é no menor bloco, 2.425 transações, por 0,001–0,002), e o modelo de tabela crua tem a menor autocorrelação residual dos cinco. A passagem de 24 mil para 82 mil linhas melhora o TabPFN em −0,010 [−0,012; −0,008] e o SAR em −0,020; o XGBoost+defasagem não melhora (+0,006 [+0,001; +0,011] na semente 42) porque seu viés de tendência mais que dobra, de +0,047 para +0,103, e come o ganho de variância. A banda

Tabela 4: Teste fora do tempo: ajuste em 2025, predição das 47.810 transações de 2026. Viés é o resíduo médio na escala logarítmica (positivo = subestimação). I de Moran na matriz k-NN-8 das coordenadas de 2026. Valores pontuais são da semente 42; faixas cobrem as três sementes.

Base de treino	Modelo	RMSE	MAPE	R^2	Viés	I de Moran
Nível A (24k)	Hedônico por OLS	0,404	32,4%	0,185	+0,033	0,408
	SAR de defasagem	0,346	27,0%	0,401	+0,032	0,224
	XGBoost + defasagem	0,288	21,8%	0,584	+0,047	0,138–0,140
	XGBoost geograficamente ponderado	0,313 (0,313–0,314)	24,0%	0,508	+0,045–+0,048	0,187–0,188
	TabPFN-3.5, *zero-shot*	**0,275**	**20,4%**	**0,622**	+0,055	**0,122**
	TabPFN-3.5, *thinking* (médio)	0,275	20,5%	0,621	+0,055	0,121
Completa (82k)	Hedônico por OLS	0,401	32,4%	0,194	+0,023	0,397
	SAR de defasagem	0,326	25,0%	0,470	+0,031	0,134
	XGBoost + defasagem	0,294[a]	21,5%[a]	0,568	+0,103[a]	0,107[a]
	XGBoost geograficamente ponderado	0,298[b]	22,1%	0,557	+0,065[b]	0,163[b]
	TabPFN-3.5, *zero-shot*	**0,265**	**19,5%**	**0,649**	+0,058	**0,092**

[a] semente 42; três sementes: RMSE 0,283–0,294, MAPE 20,9–21,5%, viés +0,070–+0,103, I 0,103–0,107. [b] semente 42; três sementes: RMSE 0,298–0,301, viés +0,065–+0,078, I 0,163–0,166.

do modelo geograficamente ponderado quase não importa aqui: com 400, 200, 100 ou 50 vizinhos, seu RMSE de 2026 no Nível A permanece entre 0,308 e 0,314. Os erros são planos entre blocos (0,23–0,31) e ao longo dos horizontes mensais (0,26–0,28 nos meses com pelo menos 500 transações): nenhum subconjunto carrega o resultado. O modo *thinking* nada acrescenta nesta perna. A hipótese sobrevive a todos os critérios, nas duas escalas, contra os três especialistas espaciais.

A limitação que merece registro. Todos os modelos subestimam 2026, um mercado em alta, e os não lineares mais (viés de +0,04 a +0,10 em ln, contra +0,02 a +0,03 do OLS e do SAR): as árvores e o TabPFN seguram o último nível observado do índice do mês em vez de extrapolar a tendência (Figura 4). A prática de avaliação aplicaria um índice de preços; aqui o viés é reportado, não corrigido.

5.3 Robustez: apenas transações financiadas

As transações financiadas carregam uma avaliação bancária e são os preços mais limpos da base. As duas pernas foram rodadas de novo apenas sobre elas: 7.211 das 24.000 linhas do Nível A para a validação por blocos, as mesmas linhas ajustadas uma vez e avaliadas nas 20.052 transações financiadas de 2026.

Tabela 5: As duas pernas apenas nas transações financiadas (semente 42).

Modelo	VC RMSE	VC MAPE	VC I	2026 RMSE	2026 MAPE	2026 I
Hedônico por OLS	0,354	28,5%	0,343	0,343	26,5%	0,491
SAR de defasagem	0,344	28,1%	0,342	0,286	22,0%	0,297
XGBoost + defasagem	0,286	23,0%	0,327	0,221	16,7%	0,160
TabPFN-3.5, *zero-shot*	**0,269**	**21,1%**	**0,279**	**0,207**	**15,3%**	**0,143**

Preços mais limpos reduzem todos os erros e deixam inalterado o ranking de um ano à frente. Na validação por blocos, o modelo de tabela crua passa à frente do XGBoost+defasagem (ΔRMSE $= -0{,}017$ $[-0{,}032;\ -0{,}003]$, $p = 0{,}049$, 8 de 10 blocos contra a semente 42 dele; 9 de 10 contra as sementes 43 e 44) e a refutação parcial do critério de resíduos não reaparece: ele deixa menos estrutura espacial que o XGBoost espacial nas duas pernas (0,279 contra 0,327–0,340 na VC). Os resultados principais não dependem das compras à vista retidas pelo filtro de subdeclaração; se algo, os preços à vista, mais ruidosos, são onde o aprendiz explicitamente espacial resiste melhor. O XGBoost geograficamente ponderado não foi rodado de novo neste subconjunto.

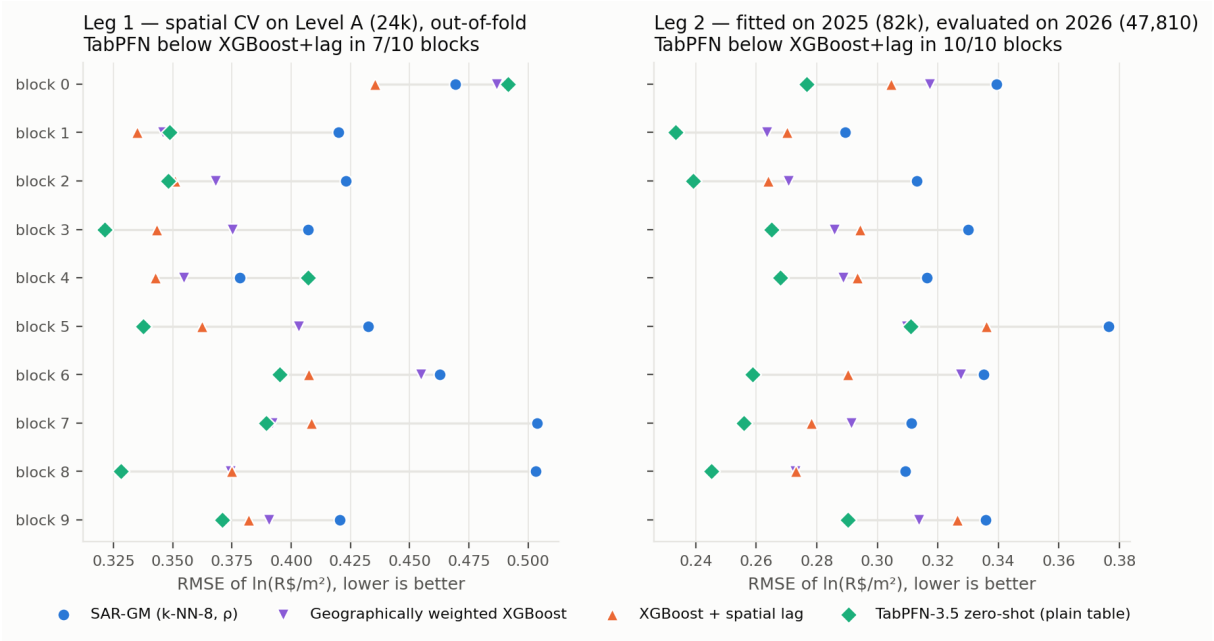


Figura 2: RMSE por bloco. Painel esquerdo: validação cruzada por blocos no Nível A (perna 1), onde o TabPFN-3.5 empata com o XGBoost+defasagem; painel direito: o teste fora do tempo de 2026 com os modelos ajustados na base completa de 2025 (perna 2), onde ele fica abaixo do XGBoost+defasagem em todos os blocos.

5.4 O que carrega a localização

A análise principal entrega ao modelo dois números. O formulário do ITBI também declara a localização como nomes — o CEP e um campo livre de bairro — e descreve o imóvel em palavras. Quatro variantes de entrada, rodadas sob protocolo idêntico e com as *baselines* intocadas, perguntam o que o modelo está de fato lendo. Cada uma foi pré-registrada com uma expectativa na *docstring* do módulo `src/model_tabpfn.py` antes da rodada; as expectativas, e onde falharam, são reportadas junto com os resultados.

O CEP no lugar das coordenadas. O CEP (*Código de Endereçamento Postal*) tem oito dígitos e, em São Paulo, costuma corresponder a uma rua ou a um trecho de rua: 10.022 valores distintos nas 24.000 linhas do Nível A e 15.938 na base completa de 2025, e nada na coluna diz qual código fica ao lado de qual. A variante remove latitude, longitude e a distância à estação (calculada a partir delas) e põe o código bruto no lugar, como texto — a única informação espacial que o modelo recebe, contra *baselines* que mantêm todos os seus insumos espaciais. A expectativa escrita era que o código recuperasse menos da metade do caminho entre o piso sem localização e o modelo com coordenadas, e perdesse para o XGBoost+defasagem nas duas pernas.

Tabela 6: O CEP no lugar das coordenadas (*zero-shot*, semente 42) contra a tabela crua. RMSE no logaritmo do valor unitário · I de Moran dos resíduos; as entradas da perna 1 da tabela crua são faixas sobre as três sementes. As *baselines* são as das Tabelas 3 e 4.

Entrada do TabPFN-3.5	Perna 2, 24k → 2026	Perna 2, 82k → 2026	Perna 1 (VC)
Apenas o CEP	0,277 · 0,129	0,268 · 0,091	0,457 · 0,502
Latitude e longitude	0,275 · 0,122	0,265 · 0,092	0,391–0,394 · 0,342–0,348

Um ano à frente, a expectativa falhou na direção favorável ao modelo: o rótulo faz o trabalho das coordenadas. O modelo só-CEP recupera 94–97% do caminho entre seu piso sem localização (0,352 no Nível A, 0,327 na base completa) e o modelo com coordenadas, e vence cada semente de cada *baseline* espacial: o XGBoost+defasagem por −0,011 (24k) e −0,014 (82k) contra a melhor

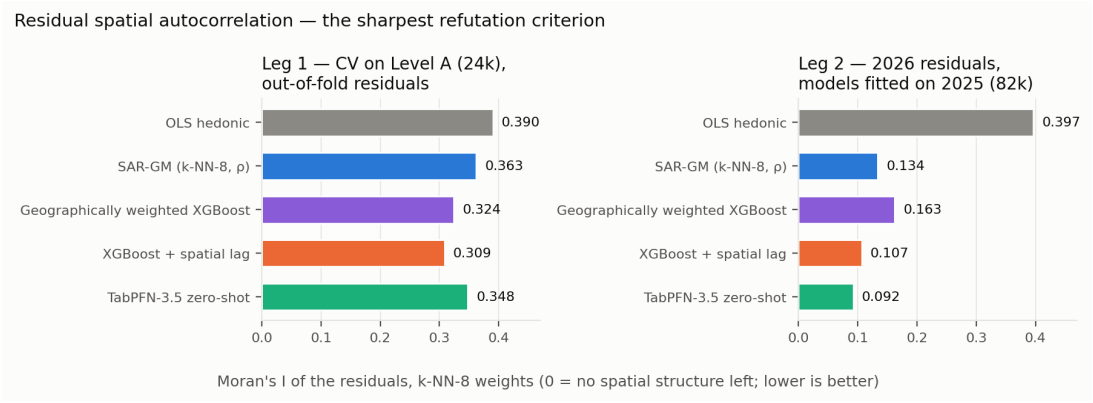
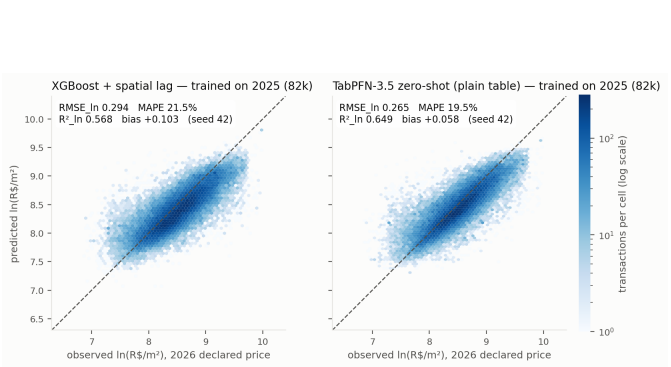
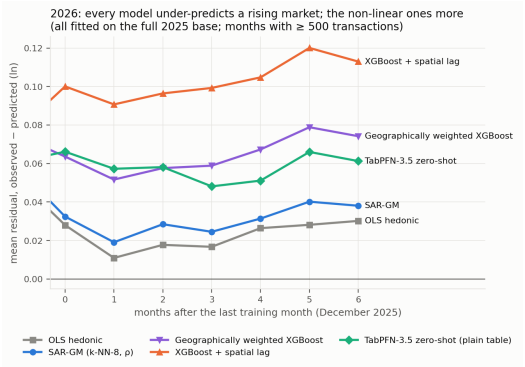


Figura 3: I de Moran dos resíduos, o critério de refutação mais afiado. Painel esquerdo: a validação por blocos (perna 1), onde o modelo de tabela crua deixa mais estrutura espacial que qualquer dos dois XGBoost — a refutação parcial; painel direito: 2026 (perna 2), onde ele deixa a menor estrutura entre os cinco modelos.



(a) Previsto contra observado, 2026.



(b) Resíduo médio por mês à frente.

Figura 4: O mercado em alta de 2026: todos os modelos subestimam, os aprendizes não lineares mais.

semente dele, em 10 de 10 blocos; o geograficamente ponderado por −0,036 e −0,029 (10 e 9 de 10); o SAR por −0,069 e −0,057 (10 de 10; Wilcoxon $p = 0{,}002$ em toda parte, $p = 0{,}004$ na linha de 9 de 10). Ele também deixa menos autocorrelação residual que os três — e o I de Moran é calculado sobre a matriz k-NN-8 das próprias coordenadas que foram negadas ao modelo. O resultado não é uma consulta de preço por código: nas transações de 2026 cujo código nunca ocorre na base de treino (22% delas contra o Nível A, 9% contra a base completa), o modelo ainda recupera 97% e 96% do sinal de localização, quase tanto quanto nos códigos já vistos (98% e 94%). Tampouco é o código informação mais rica do que as *baselines* tinham: dentro do TabPFN ele chega a 0,004 do par de coordenadas e, somado a elas, nada muda (abaixo); o XGBoost tinha as coordenadas e, por cima, uma defasagem, eixos rotacionados e a distância à estação.

Onde o rótulo para é numa parte da cidade nunca vista. Na perna 1 os códigos de um bloco deixado de fora estão ausentes do treino por construção (97–100%), e ali o código carrega pior do que nada: o modelo cai abaixo do próprio piso sem localização (0,457 contra 0,440), perde para o XGBoost+defasagem no erro agregado (+0,069 a +0,072, 4 de 10 blocos) e deixa a maior autocorrelação espacial de qualquer modelo do estudo ($I = 0{,}502$) — um bloco inteiro de códigos desconhecidos é precificado como uma única incógnita, e o erro se desloca em bloco. Esta perna se comportou como a expectativa escrita dizia, e pior. Coordenadas extrapolam para um distrito não visto; um rótulo, não. Por que códigos nunca vistos, em meio a códigos conhecidos, ainda funcionam não está resolvido; a hipótese principal é a ordem: os CEPs brasileiros são atribuídos geograficamente, de modo que códigos vizinhos em geral significam ruas vizinhas, e o teste que decidiria a questão (uma bijeção aleatória fixa dos códigos, que destrói a ordem e preserva as

identidades) está desenhado, mas não foi executado.

O endereço somado às coordenadas. Acrescentar o CEP e o campo de bairro à tabela crua, tal como preenchidos, move o RMSE em menos de 0,006 em qualquer direção em todos os testes e combinações, o MAPE em no máximo 0,3 ponto, e o I de Moran residual em no máximo 0,019 na VC por blocos e 0,008 um ano à frente; a margem sobre o XGBoost+defasagem fica onde estava. Duas colunas numéricas cruas já carregam o que o endereço carrega. Uma observação lateral é reportada sem explicação: com os dois nomes na tabela, a subestimação média de 2026 cai de +0,055 para +0,045 em ln no Nível A e de +0,058 para +0,043 na base completa, com o RMSE parado.

A unidade e o edifício como escritos. O complemento da unidade do formulário (`AP 201 E 3VGS`: apartamento 201 com três vagas) e o campo *Referência*, que em geral nomeia o edifício (`EDIFICIO THE PARK`), entram como texto bruto ao lado das coordenadas; nada é interpretado. A expectativa escrita era de um ganho pequeno, no máximo, um ano à frente, onde os mesmos edifícios voltam a vender, com a perna 1 como controle quase negativo. A expectativa errou o lugar.

Tabela 7: O texto da unidade e do edifício somado à tabela crua (*zero-shot*, semente 42). Δ é texto − tabela crua, IC 95% por *bootstrap* de blocos; blocos vencidos pela variante com texto.

	Tabela crua	+ texto da unidade e do edif.	ΔRMSE [IC 95%] · blocos
Perna 1, VC por blocos	0,3938 · 32,2% · I 0,348	0,3835 · 30,8% · 0,331	−0,0103 [−0,0161; −0,0031] · 8/10
Perna 2, 24k → 2026	0,2750 · 20,4% · 0,122	0,2750 · 20,6% · 0,122	+0,0000 [−0,0011; +0,0010] · 6/10
Perna 2, 82k → 2026	0,2649 · 19,5% · 0,092	0,2610 · 19,2% · 0,086	−0,0039 [−0,0049; −0,0031] · 10/10

O maior ganho está no distrito nunca visto, contra cada uma das três sementes da tabela crua (−0,007 a −0,010, todos os intervalos fora do zero). Ali o texto transforma o empate com o XGBoost geograficamente ponderado em vitória (−0,023 a −0,026, 9 de 10 blocos, $p = 0{,}027$), mantém um empate pendendo para o TabPFN contra o XGBoost+defasagem e entrega o menor MAPE de qualquer modelo daquela perna (30,8%). Não é casamento de cadeias de caracteres: 92% dos nomes de edifício de um bloco deixado de fora nunca ocorrem nas dobras de treino, e complementos nunca vistos como texto exato ganham tanto quanto os já vistos (−0,014 contra −0,013). O ganho está nos formulários que mencionam vaga (−0,034), unidades comerciais (−0,023) ou um edifício nomeado (−0,017): o que transfere para um distrito não visto é o que as palavras dizem, não o edifício que apontam. O critério dos resíduos estreita, mas permanece: o I de Moran cai de 0,348 para 0,331, ainda acima das duas variantes de XGBoost.

***Thinking* com os blocos como grupos.** O modo *thinking* pode separar sua validação interna por uma coluna de agrupamento; com o bloco espacial como grupo, a validação interna passa a deixar distritos inteiros de fora, como a perna 1 faz. Contra o *thinking* sem grupos, a mudança na perna 1 é +0,0038 [−0,0055; +0,0149] (3 de 10 blocos) e o I residual vai de 0,342 a 0,350: o agrupamento não fecha a lacuna. Um ano à frente a mudança é de −0,0014 [−0,0021; −0,0007] (9 de 10 blocos) e ele reduz a subestimação média de +0,055 para +0,043, mas ali o rótulo do bloco também informa ao modelo a que parte da cidade pertence uma linha de 2026, de modo que o pequeno ganho não é um efeito puro de calibração. Num distrito não visto, o limite é de informação, não de desenho de validação: o texto move a perna 1, o agrupamento não.

5.5 Explicando uma estimativa

O avaliador que assina um laudo precisa dizer por quê. Como o modelo é servido por uma API, a explicação é o SHAP por permutação, agnóstico ao modelo [13], sobre 50 transações estratificadas de 2026 que o modelo nunca viu, com cada uma das 27.217 linhas previstas em



(a) Média de |SHAP| por atributo e tipo.

(b) Uma avaliação, do valor-base à estimativa.

Figura 5: SHAP por permutação em 50 transações de 2026 (*masker* independente, fundo de 20 linhas), com o modelo recarregado de seu registro em cache. Valores na escala logarítmica; e^{SHAP} é o multiplicador sobre o valor unitário.

cache para reprodução *offline*. Recarregado de seu registro em cache, o modelo reproduz as predições que está explicando (RMSE de 0,296 em ln nas 50 linhas), de modo que as atribuições descrevem a rodada que foi avaliada. Longitude (média de |SHAP| de 0,184, um multiplicador típico de ×1,20 sobre o valor unitário) e latitude (0,143, ×1,15) são os dois insumos mais fortes, à frente da tipologia (0,127), da área construída (0,112) e da idade (0,082). As direções coincidem com a experiência do avaliador: idade e distância à estação puxam o valor unitário para baixo, o padrão construtivo empurra para cima, áreas construídas maiores reduzem o preço por metro quadrado. As duas coordenadas cruas carregam, dentro do modelo, o sinal que as *baselines* codificam com uma matriz de pesos — e a Seção 5.4 mostra que o que elas carregam, dentro de um mercado observado, é a localização como identificador, não geometria.

6 Discussão

Lidas juntas, as duas pernas traçam uma linha. Dentro de um mercado que o modelo viu — a mesma cidade, um a sete meses à frente —, o aprendizado em contexto sobre 24 mil a 82 mil linhas recupera a estrutura de vizinhança de duas colunas cruas e precifica melhor do que os modelos construídos para codificá-la, por todos os critérios pré-registrados, autocorrelação residual incluída. A variante com o CEP afia a leitura: dentro desse mercado, o modelo não precisa de geometria alguma, apenas de um identificador fino de localização, e precifica códigos nunca vistos, em meio a códigos conhecidos, quase tão bem quanto os conhecidos. Do outro lado da linha, num distrito sem vendas na base de treino, o identificador colapsa, as coordenadas ainda extrapolam, e a defasagem espacial explícita justifica-se no critério dos resíduos: a refutação parcial da perna 1 é o preço medido de não modelar o espaço quando o bloco de teste é terreno novo. Esse preço encolhe com mais informação — o texto livre do formulário reduz a lacuna e o erro — e não aparece nos preços financiados, auditados pelo banco, contra o XGBoost+defasagem; na análise principal, porém, ele não desaparece, e é reportado como encontrado.

O único erro sistemático comum a todos os modelos é a tendência. Todos subestimam o mercado em alta de 2026, os aprendizes não lineares mais (+0,04 a +0,10 em ln, contra +0,02 a +0,03 dos modelos lineares), porque as árvores e o modelo de fundação seguram o último nível observado do índice do mês em vez de extrapolá-lo. A prática de avaliação corrige isso com um índice de preços como rotina; nenhuma correção foi aplicada aqui, para que a comparação permaneça entre modelos tal como ajustados. O viés diz respeito ao nível e não à localização: os mapas de resíduos e o I de Moran, que a tendência desloca uniformemente, continuam separando os modelos.

O balanço de engenharia é curto. O SAR precisa de uma matriz de pesos por dobra; o XGBoost espacial, de uma defasagem interna à dobra, eixos rotacionados e 30 tentativas de ajuste

aninhado (cerca de 15 minutos de calibração na base completa); o XGBoost geograficamente ponderado, de 1.000 modelos locais e uma busca interna de banda e mistura (cerca de dez minutos). O TabPFN-3.5 precisa da tabela: um ajuste de 9 a 15 segundos e, onde um CEP já está no formulário, nem de um geocodificador. Para a avaliação em massa sob a norma brasileira NBR 14653-2, seguem-se duas consequências. Os graus de precisão da norma são definidos sobre estimativas intervalares, e o modelo devolve quantis preditivos sem engenharia adicional — eles estão em cache para todos os ajustes *zero-shot* deste estudo, e a análise de cobertura é o passo seguinte natural. E a exigência de fundamentação da norma pode ser atendida, em parte, por atribuição agnóstica ao modelo: as direções do SHAP acima são as que um avaliador defenderia.

Os limites da evidência são estes. As coordenadas são centroides de quadra fiscal, de modo que a localização é resolvida na quadra e todas as transações de uma mesma quadra coincidem; um *jitter* determinístico submétrico desfaz os empates apenas para as matrizes de pesos. Os preços são autodeclarados; o filtro de subdeclaração remove o acúmulo detectável, não o fenômeno, e a robustez só-financiados limita o seu efeito. O estudo cobre uma cidade e um período, e o modelo de fundação é servido por uma API: seus internos não são inspecionáveis (daí não haver atribuição exata por linha para a cabeça de regressão) e a versão hospedada pode mudar, embora os pesos estejam publicados para uso em pesquisa e cada resposta da API esteja em cache. As variantes de entrada do TabPFN rodaram com uma única semente; a dispersão entre sementes da tabela crua na perna 1 (0,003 em ln) fica muito abaixo de todas as margens da perna 2, mas os empates da perna 1 devem ser lidos com essa largura em mente. O XGBoost geograficamente ponderado é uma aproximação do estimador publicado — modelos locais em 1.000 pontos de regressão em vez de em cada linha de treino, hiperparâmetros locais compartilhados, piso de banda de 50 vizinhos que a busca interna escolheu em 8 de 10 dobras —, defensável nos termos da própria regressão geograficamente ponderada e balizada pela sensibilidade de banda reportada acima. O teste do CEP embaralhado, que resolveria por que códigos não vistos funcionam, está desenhado, não executado.

7 Conclusão

A hipótese era que um modelo de fundação tabular recebendo as coordenadas como duas colunas numéricas simples prevê preços espacialmente correlacionados tão bem quanto, ou melhor que, modelos que codificam a dependência espacial explicitamente, e ela foi posta em risco contra três desses especialistas — SAR, XGBoost com defasagem espacial e um XGBoost geograficamente ponderado —, sobre 130.000 preços de transação declarados, com os critérios de refutação escritos antes. Um ano à frente, dentro do mercado observado, a hipótese sobrevive a todos os critérios nas duas escalas de treino: erro agregado menor que o do SAR, do XGBoost com defasagem espacial e do XGBoost geograficamente ponderado, vitórias em pelo menos 9 dos 10 blocos espaciais contra cada semente de cada oponente, e a menor autocorrelação espacial residual dos cinco modelos — um veredito que se mantém mesmo quando as coordenadas são substituídas por um CEP bruto. Num distrito nunca visto, ela empata com as duas variantes de XGBoost no erro, vence o SAR e é parcialmente refutada no critério dos resíduos, deixando mais estrutura espacial que qualquer dos dois XGBoost; o texto livre do formulário estreita essa lacuna e o subconjunto financiado a dissolve contra o XGBoost+defasagem, mas na análise principal ela permanece. O veredito poderia mudar em outro lugar: outra cidade ou mercado, ofertas em vez de preços declarados, uma versão do modelo com atribuição por linha na regressão, ou o teste do código embaralhado são os experimentos que o moveriam. Como está, dentro de um mercado com histórico de vendas, nenhuma das maquinarias espaciais testadas aqui melhorou a tabela crua; o seu valor remanescente, medido, é a extrapolação para terreno sem vendas.

Reprodutibilidade e disponibilidade dos dados

Código, dados limpos, respostas do modelo em cache e todos os números deste artigo estão em `https://github.com/abenvenho/tabpfn-itbi-sp` (Apache-2.0); todos os dados de origem são públicos (dados abertos municipais sob a Lei de Acesso à Informação). O *pipeline* foi reexecutado a partir de um clone limpo: as três bases foram reconstruídas byte a byte idênticas a partir das planilhas públicas brutas, e as rodadas de fumaça e de *baseline* devolveram os números documentados. Todo número citado neste manuscrito é conferido contra os resultados versionados por `paper/check_numbers.py`.

Agradecimentos

Este estudo foi realizado como entrada no *hackathon* TabPFN-3.5 da Prior Labs, cujos créditos de API para participantes custearam as rodadas do modelo.

Declaração de assistência de IA. O código deste estudo foi desenvolvido com a assistência de ferramentas de IA em nuvem — Claude (modelos Fable e Opus) e ChatGPT (Astra) — e dos modelos executados localmente Qwen 3.8 Next Flash e Qwen 3 Coder Next. As ferramentas de nuvem também auxiliaram na redação, tradução, pesquisa bibliográfica, geração de figuras e revisão de texto. O desenho experimental, as decisões metodológicas, a análise dos resultados e as conclusões são do autor, que revisou e assume a responsabilidade por todo o conteúdo.

Referências

[1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631, 2019.

[2] Luc Anselin. *Spatial Econometrics: Methods and Models*. Kluwer Academic Publishers, Dordrecht, 1988.

[3] Agnaldo Calvi Benvenho. Métodos não lineares versus regressão espacial na avaliação de apartamentos: um estudo comparativo em Belo Horizonte. In *Anais da III Conferência de Engenharia de Avaliações e Diagnóstica (CEAD)*, September 2026. In Portuguese. Best-paper award in appraisal engineering.

[4] Agnaldo Calvi Benvenho. Transformers na avaliação de imóveis residenciais: comparação entre regressão linear múltipla, FT-Transformer e TabPFN v2 com dados de ITBI de São Paulo. In *Anais do I Fórum Nacional IGEL & SOBREA*, August 2026. In Portuguese.

[5] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.

[6] Rui Deng, Ziqi Li, and Mingshu Wang. Do foundation models work for geospatial tabular data? An investigation of TabPFN and a proposed enhancement based on geospatial sparse attention. *International Journal of Geographical Information Science*, 2026. doi: 10.1080/13658816.2026.2691066. Early online publication.

[7] A. Stewart Fotheringham, Chris Brunsdon, and Martin Charlton. *Geographically Weighted Regression: The Analysis of Spatially Varying Relationships*. Wiley, Chichester, 2002.

[8] George Grekousis. Geographical-XGBoost: a new ensemble model for spatially local regression based on gradient-boosted trees. *Journal of Geographical Systems*, 27(2):169–195, 2025. doi: 10.1007/s10109-025-00465-4.

[9] Noah Hollmann, Samuel Müller, Katharina Eggensperger, and Frank Hutter. TabPFN: A transformer that solves small tabular classification problems in a second. In *International Conference on Learning Representations (ICLR)*, 2023.

[10] Noah Hollmann, Samuel Müller, Lennart Purucker, Arjun Krishnakumar, Max Körfer, Shi Bin Hoo, Robin Tibor Schirrmeister, and Frank Hutter. Accurate predictions on small data with a tabular foundation model. *Nature*, 637:319–326, 2025. doi: 10.1038/s41586-024-08328-6.

[11] Harry H. Kelejian and Ingmar R. Prucha. A generalized spatial two-stage least squares procedure for estimating a spatial autoregressive model with autoregressive disturbances. *The Journal of Real Estate Finance and Economics*, 17(1):99–121, 1998.

[12] James LeSage and R. Kelley Pace. *Introduction to Spatial Econometrics*. Chapman and Hall/CRC, 2009.

[13] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774, 2017.

[14] Hanna Meyer and Edzer Pebesma. Predicting into unknown space? Estimating the area of applicability of spatial prediction models. *Methods in Ecology and Evolution*, 12(9):1620–1633, 2021.

[15] Anders Bjørn Møller, Amélie Marie Beucher, Nastaran Pouladi, and Mogens Humlekrog Greve. Oblique geographic coordinates as covariates for digital soil mapping. *SOIL*, 6:269–289, 2020. doi: 10.5194/soil-6-269-2020.

[16] P. A. P. Moran. Notes on continuous stochastic phenomena. *Biometrika*, 37(1/2):17–23, 1950.

[17] Prior Labs Team. TabPFN-3: Technical report. Technical report, Prior Labs, 2026. arXiv:2605.13986.

[18] Prior Labs Team. TabPFN-3.5: Technical report. Technical report, Prior Labs, 2026. arXiv:2609.17895.

[19] Sergio J. Rey and Luc Anselin. PySAL: A Python library of spatial analytical methods. *The Review of Regional Studies*, 37(1):5–27, 2007.

[20] David R. Roberts, Volker Bahn, Simone Ciuti, Mark S. Boyce, Jane Elith, Gurutzeta Guillera-Arroita, Severin Hauenstein, José J. Lahoz-Monfort, Boris Schröder, Wilfried Thuiller, David I. Warton, Brendan A. Wintle, Florian Hartig, and Carsten F. Dormann. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929, 2017.

[21] Sherwin Rosen. Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy*, 82(1):34–55, 1974.

[22] Jonas Schmidinger, Viacheslav Barkov, Sebastian Vogel, Martin Atzmueller, and Gerard B. M. Heuvelink. Kriging prior regression: A case for kriging-based spatial features with TabPFN in soil mapping. Technical report, arXiv, 2026. arXiv:2509.09408.

[23] Waldo R. Tobler. A computer movie simulating urban growth in the Detroit region. *Economic Geography*, 46:234–240, 1970.

[24] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems 30*, pages 5998–6008, 2017.

A XGBoost geograficamente ponderado: piloto de viabilidade

A implementação publicada (`geoxgboost`) calibra um XGBoost local, com sua própria busca em grade, em cada linha de treino, sobre uma matriz densa de distâncias $n \times n$. Um piloto com 200

linhas e um candidato de banda levou 18,7 s (0,093 s por unidade espacial), o que extrapola para cerca de meia hora por candidato de banda por dobra nas 19.117 linhas de treino de uma dobra do Nível A, cerca de dois dias para dez candidatos em dez dobras, e 2,9 GB de matriz de distâncias por dobra na máquina do estudo (2 vCPU, 7 GB de RAM; `results/gxgb_timing_pilot.json`). A aproximação por pontos de regressão da Seção 4 preserva o estimador — modelos locais, pesos bi-quadrados, mistura com um modelo global, escolha aninhada da banda — em cerca de um minuto por ajuste e dez por calibração.

B Hiperparâmetros e configurações dos modelos

XGBoost com atributos espaciais. Optuna aninhado, 30 tentativas TPE por dobra externa, *leave-one-block-out* interno sobre os blocos de treino, parada antecipada com até 3.000 rodadas. Espaço de busca: taxa de aprendizado 0,01–0,2 (log), profundidade máxima 3–10, peso mínimo por folha 1–50 (log), *subsample* 0,5–1, *colsample_ bytree* 0,4–1, λ 10^{-3}–30 (log), α 10^{-3}–10 (log), γ 10^{-4}–1 (log). Selecionados para o ajuste fora do tempo na base completa (semente 42): taxa de aprendizado 0,049, profundidade 7, peso mínimo 2,0, *subsample* 0,89, *colsample* 0,56, λ 0,0033, α 0,0041, γ 0,0031, 398 rodadas; RMSE interno 0,351; tempo de calibração 901 s (`results/xgb_params_*.json`).

XGBoost geograficamente ponderado. $M = 1.000$ pontos de regressão (K-médias das coordenadas de treino); modelos locais com hiperparâmetros compartilhados (300 rodadas, taxa de aprendizado 0,05, profundidade 4); modelo global com 800 rodadas, taxa 0,05, profundidade 6; uma consulta é prevista pela média, com pesos inversos à distância, de seus 3 modelos locais mais próximos, combinada por α. Banda k e α por validação cruzada interna aninhada por blocos, grades na Seção 4 (os valores da grade escalam com o tamanho do treino, daí 40–176 nas dobras de 19–21 mil linhas do Nível A). Escolhidos: no Nível A, k por dobra entre 40 e 176 (perna 1) e $k = 50$ (perna 2); na base completa, $k = 342$; $\alpha = 0{,}5$ em toda parte (`results/gxgb_params_*.json`).

TabPFN-3.5. Modelo hospedado (`tabpfn-client` 0.6.0), criado por `create_default_for_version` com a versão `"v3.5"`; cabeça de regressão, *zero-shot* salvo indicação. Modo *thinking*: `thinking_effort` médio ou alto, `thinking_metric = "rmse"`, tempo-limite de 2.400 s; a variante agrupada passa o bloco espacial como `group_col`. Os ajustes com as 82.187 linhas usam `ignore_pretraining_limits`. Quantis preditivos são solicitados e armazenados em cache em todo ajuste *zero-shot*. Toda resposta da API fica em cache sob `results/tabpfn_cache/`, de modo que o protocolo completo roda de novo *offline* a partir das predições em cache.