

MÉTODOS NÃO LINEARES VERSUS REGRESSÃO ESPACIAL NA AVALIAÇÃO DE APARTAMENTOS: UM ESTUDO COMPARATIVO EM BELO HORIZONTE

Resumo: A avaliação de imóveis fundamenta-se, na prática corrente, na regressão linear múltipla estimada por mínimos quadrados ordinários, cuja hipótese de independência das observações é frequentemente violada em dados urbanos. Este trabalho compara, sobre uma base única de 5.005 apartamentos de Belo Horizonte, cinco abordagens de modelagem do valor unitário (R\$/m²): a regressão linear clássica (OLS), dois modelos espaciais lineares — de defasagem (SAR) e de erro (SEM) —, um modelo espacial semiparamétrico (PS-SAR, que combina *P-splines* e defasagem espacial) e um modelo de fundação para dados tabulares, o TabPFN v3, que não incorpora explicitamente a estrutura espacial. A validação empregou reamostragem cruzada por blocos espaciais ($k = 10$, por *K-means* das coordenadas), matriz dos oito vizinhos mais próximos padronizada por linha, e métricas computadas fora da amostra. O TabPFN v3 obteve o melhor desempenho ($R^2 = 0,538$; MAPE = 24,4%; RMSE de 0,312 na escala logarítmica), com erros absolutos menores que os de todos os concorrentes no teste de Wilcoxon pareado, sob o protocolo adotado ($p < 0,001$). Entre os modelos espaciais, o SAR foi o melhor ($R^2 = 0,445$); o PS-SAR, embora tenha reduzido a autocorrelação dos resíduos (*I* de Moran de 0,397, ante 0,478 do SAR), não o superou fora da amostra. Detectou-se autocorrelação forte na variável resposta (*I* de Moran de 0,476; $p < 0,001$) e nos resíduos do OLS. Conclui-se que, sob o protocolo adotado, um método não linear de uso direto captou parcela relevante do padrão espacial e superou as abordagens espaciais tradicionais.

Palavras-chave: avaliação de imóveis. Regressão espacial. Aprendizado de máquina. Modelos de fundação. TabPFN.

Abstract: *Real estate appraisal typically relies on multiple linear regression estimated by ordinary least squares, whose assumption of independent observations is often violated in urban data marked by spatial dependence. This paper compares, on a single base of 5,005 apartments in Belo Horizonte, Brazil, five approaches to modeling the unit value (BRL/m²): classical linear regression (OLS), two linear spatial models — spatial lag (SAR) and spatial error (SEM) —, a semiparametric spatial model (PS-SAR, combining *P-splines* and a spatial lag) and a tabular foundation model, TabPFN (version 3), a nonlinear method that does not explicitly incorporate spatial structure. Validation used spatial block cross-validation ($k = 10$, *K-means* clustering of coordinates), a row-standardized eight-nearest-neighbor weights matrix, and out-of-sample metrics. TabPFN v3 achieved the best performance ($R^2 = 0.538$; MAPE = 24.4%; log-scale RMSE of 0.312), showing lower absolute errors than all competitors in the paired Wilcoxon test under the adopted protocol ($p < 0.001$). Among spatial models, SAR was best ($R^2 = 0.445$); PS-SAR sharply reduced residual spatial autocorrelation (Moran's *I* of 0.397 versus 0.478 for SAR) but did not surpass SAR in out-of-sample prediction. Strong, significant spatial autocorrelation was found in the response (Moran's *I* of 0.476; $p < 0.001$) and in OLS residuals. Under the adopted protocol, a directly usable nonlinear method without explicit spatial modeling captured a relevant share of the observed spatial pattern and outperformed traditional spatial approaches.*

Keywords: *real estate appraisal. Spatial regression. Machine learning. Foundation models. TabPFN.*

1. Introdução

A avaliação de imóveis ocupa posição central em decisões econômicas, jurídicas e administrativas, presente em financiamentos, garantias reais, partilhas, desapropriações e perícias judiciais. No Brasil, a atividade é disciplinada pelas normas ABNT NBR 14653-1 e NBR 14653-2, que estabelecem os métodos admitidos e os critérios de enquadramento dos laudos quanto aos graus de fundamentação e de precisão (ABNT, 2019; ABNT, 2011). O método mais difundido é o comparativo direto de dados de mercado, operacionalizado, na prática corrente, pela regressão linear múltipla estimada por mínimos quadrados ordinários (OLS).

O modelo hedônico, formalizado por Rosen (1974), decompõe o preço de um bem heterogêneo como função de seus atributos, refletindo o valor marginal implícito de cada característica. Especificada em geral de forma linear ou log-linear, a função permite interpretar os coeficientes como variações marginais ou elasticidades. Duas dificuldades a acompanham. A primeira é a não linearidade: área privativa, andar, padrão construtivo e localização guardam relações não lineares com o preço, incluindo retornos marginais decrescentes (MALPEZZI, 2003). A segunda, mais séria do ponto de vista inferencial, é a dependência espacial: imóveis próximos tendem a apresentar preços semelhantes (TOBLER, 1970), o que viola a independência dos erros e compromete a eficiência das estimativas e a validade dos testes (ANSELIN, 1988).

A econometria espacial responde com modelos que incorporam a estrutura de vizinhança de forma explícita, seja na variável dependente (SAR), seja no termo de erro (SEM); extensões semiparamétricas, como o PS-SAR, acrescentam flexibilidade funcional por meio de funções suaves estimadas por *P-splines* e de uma superfície espacial contínua (MÍNGUEZ; BASILE; DURBÁN, 2020). Em paralelo, o aprendizado de máquina trouxe preditores de elevada acurácia, frequentemente operados como caixas-pretas, e desse avanço emergiram os modelos de fundação para dados tabulares, dos quais o TabPFN é o expoente: uma rede pré-treinada que realiza inferência bayesiana aproximada em uma única passada, dispensando ajuste iterativo e busca de hiperparâmetros (HOLLMANN et al., 2025).

A literatura tem comparado modelos hedônicos e algoritmos de aprendizado de máquina na avaliação imobiliária, em geral com vantagem preditiva para os últimos (GYGER, 2025; MURA; CONTRERAS, 2025), e o tratamento espacial é reconhecido como fator de ganho de acurácia em bases urbanas brasileiras (BILYK; RIBEIRO; CORRÊA, 2020). Não se identificou, até a data desta pesquisa, trabalho que aplicasse o TabPFN à avaliação de imóveis, tampouco que o confrontasse com a regressão espacial linear e semiparamétrica sob um mesmo protocolo de validação espacial. Essa lacuna motiva o presente estudo.

O objetivo é comparar, sobre uma base real de 5.005 apartamentos de Belo Horizonte, cinco abordagens de modelagem do valor unitário: OLS, SAR, SEM, PS-SAR e TabPFN v3. Três perguntas norteiam a investigação: **(i)** o tratamento espacial explícito melhora a predição fora da amostra em relação ao OLS? **(ii)** a flexibilização não linear do modelo espacial traz ganho adicional? **(iii)** um método não linear de uso direto, sem modelagem espacial explícita, é competitivo com as abordagens espaciais?

Como contribuições, destacam-se a primeira aplicação, ao que se apurou, do TabPFN à avaliação de imóveis; a comparação sob validação cruzada por blocos espaciais, com diagnóstico da autocorrelação dos resíduos; a comparação da interpretabilidade inerente às classes de modelos; e a discussão do resultado à luz do enquadramento normativo brasileiro.

2. Referencial teórico

2.1 Avaliação imobiliária e modelos hedônicos

A teoria dos preços hedônicos (ROSEN, 1974) sustenta que o preço de um imóvel resulta da soma dos valores implícitos de seus atributos. Adota-se a especificação log-linear usual, apresentada na Eq. (1), em que o logaritmo do valor unitário é explicado por uma combinação linear dos atributos mais um erro aleatório.

$$\ln\left(\frac{V}{m^2}\right) = \beta_0 + \sum_{k=1}^K \beta_k x_k + \varepsilon, (1)$$

A transformação logarítmica da resposta e das variáveis contínuas justifica-se pela distribuição log-normal desses atributos e pela estabilização da variância, confirmada por análise de Box e Cox (1964). Sob homoscedasticidade e independência dos erros, o estimador de mínimos quadrados ordinários é o de menor variância entre os lineares não viesados; a violação da independência, típica de dados espaciais, retira essa propriedade e enviesa a inferência (GREENE, 2018).

2.2 Dependência espacial e regressão espacial

A dependência espacial manifesta-se quando o valor observado em uma localização se correlaciona com os das localizações vizinhas. Sua mensuração usual é o I de Moran (MORAN, 1950), definido pela Eq. (2), que confronta a covariância entre pares de observações vizinhas, definidos pela matriz de vizinhança W , com a variância total da variável; valores positivos e significativos indicam agrupamento espacial de valores semelhantes.

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (y_i - \bar{y})(y_j - \bar{y})}{\sum_i (y_i - \bar{y})^2}, (2)$$

O modelo de defasagem espacial (*spatial lag*, SAR) incorpora a média ponderada dos vizinhos da variável dependente como regressor adicional, conforme a Eq. (3):

$$y = \rho Wy + X\beta + \varepsilon, (3)$$

em que ρ é o coeficiente autorregressivo espacial. O modelo de erro espacial (*spatial error*, SEM), por sua vez, atribui a dependência ao termo de erro, conforme a Eq. (4):

$$y = X\beta + u, \quad u = \lambda Wu + \varepsilon, (4)$$

em que λ é o coeficiente de autocorrelação do erro. A escolha entre as especificações apoia-se em testes de multiplicadores de Lagrange e em suas versões robustas (ANSELIN, 1988; LESAGE; PACE, 2009).

2.3 Regressão espacial semiparamétrica (PS-SAR)

O PS-SAR generaliza o SAR ao substituir a parte paramétrica por funções suaves e ao acrescentar uma superfície espacial contínua (MÍNGUEZ; BASILE; DURBÁN, 2020). Em sua forma para dados de corte transversal, tem-se a Eq. (5),

$$y_i = \rho \sum_j w_{ij} y_j + \sum_{\delta} g_{\delta}(x_{\delta,i}) + \tilde{f}(s_{1i}, s_{2i}) + \varepsilon_i, \quad (5)$$

em que g são funções não lineares dos atributos e f , uma superfície geoaditiva das coordenadas. Cada função é representada por combinação de *B-splines* cuja suavidade é controlada por penalidade sobre diferenças dos coeficientes adjacentes (EILERS; MARX, 1996). A superfície geoaditiva filtra a tendência espacial e a transfere para a média da resposta, reduzindo a autocorrelação dos resíduos. A estimação emprega máxima verossimilhança restrita, na representação de modelo misto (MÍNGUEZ; BASILE; DURBÁN, 2020).

2.4 Modelos de fundação para dados tabulares: TabPFN

O TabPFN (Tabular Prior-Data Fitted Network) é uma rede *transformer* pré-treinada em milhões de conjuntos sintéticos gerados a partir de uma distribuição *a priori* sobre relações causais plausíveis (HOLLMANN et al., 2025). Não realiza ajuste iterativo: o conjunto de treinamento é fornecido como contexto e a predição é obtida em uma única passada direta, mecanismo denominado aprendizado em contexto. O modelo aproxima a distribuição preditiva a posteriori marginalizada sobre o espaço de hipóteses, o que confere robustez em amostras de porte pequeno a moderado; a versão 3 amplia a capacidade da arquitetura e o repertório de *priors* (GRINSZTAJN et al., 2026). Registre-se que o TabPFN não modela a dependência espacial de forma explícita: a localização, quando incluída, entra apenas como par de atributos, à semelhança de trabalhos que injetam variáveis espaciais em modelos tabulares (SCHMIDINGER et al., 2025).

2.5 Interpretabilidade comparativa

As classes comparadas oferecem níveis distintos de interpretação. No OLS, sinais, magnitudes e incertezas dos coeficientes permitem leitura paramétrica direta. No SAR e no SEM, os parâmetros ρ e λ caracterizam, respectivamente, a defasagem da resposta e a autocorrelação do erro; no SAR, os efeitos marginais devem ser decompostos em impactos diretos, indiretos e totais, em razão da realimentação espacial (LESAGE; PACE, 2009). No PS-SAR, as curvas suaves dos atributos e a superfície geoaditiva tornam inspecionáveis as relações não lineares e o componente espacial. O TabPFN v3 não fornece parâmetros de interpretação econômica imediata, o que desloca a explicação para métodos pós-hoc, como os valores SHAP (LUNDBERG; LEE, 2017), que descrevem associações preditivas e não efeitos causais. Como não foram calculadas atribuições SHAP neste estudo, a comparação de interpretabilidade restringe-se à transparência estrutural e à possibilidade de inspeção de cada classe.

2.6 Enquadramento normativo


A NBR 14653-2, no item 8.2.1.4.3 (Tratamento Científico), admite, além da inferência estatística clássica, o emprego de redes neurais artificiais, da análise envoltória de dados e da regressão espacial, desde que justificados teórica e praticamente, com validação quando pertinente (ABNT, 2011). O dispositivo confere respaldo normativo tanto aos modelos espaciais quanto aos métodos não lineares aqui examinados. A norma não fixa limiar mínimo de coeficiente de determinação para o tratamento científico, de modo que as métricas reportadas devem ser lidas como evidência comparativa, e não como critério normativo de grau.

3. Materiais e métodos

A Fig. 1 sintetiza o desenho da pesquisa. Uma única amostra analítica alimenta todos os métodos, e um mesmo particionamento espacial — dez blocos obtidos por *K-means* das coordenadas — governa a separação entre treinamento e teste em todas as rodadas. Em cada uma delas, nove blocos formam o conjunto de treinamento e um bloco, reservado, serve de teste; ao fim das dez rodadas, cada imóvel foi predito exatamente uma vez fora da amostra. As predições assim reunidas, uma por imóvel e por método, constituem a base comum sobre a qual se calculam a acurácia preditiva, o diagnóstico de dependência espacial remanescente e a comparação dos erros. O diagrama também explicita a via pela qual cada classe de modelo acessa a informação locacional: os modelos espaciais a incorporam pela matriz de vizinhança W , ao passo que o TabPFN v3, desprovido de mecanismo espacial próprio, a recebe como par de atributos de latitude e longitude. A disposição horizontal dos cinco métodos não denota hierarquia de desempenho.

Figura 1 — Arquitetura geral do estudo e protocolo comparativo

Arquitetura geral do estudo e protocolo comparativo



Leitura integrada: desempenho · dependência residual · interpretabilidade por classe

O protocolo mantém a separação espacial entre treinamento e teste em todos os modelos.

Fonte: elaborado pelos Autores

3.1 Construção da base de dados

A base de modelagem originou-se de um cadastro com 29.246 ofertas de apartamentos residenciais de Belo Horizonte, com atributos físicos e endereço. O saneamento e a espacialização seguiram uma cadeia documentada e reproduzível. Dessa base, selecionaram-se 13.518 registros com número no endereço, submetidos à geocodificação, dos quais 12.934 obtiveram coordenadas geográficas válidas. Restringiu-se a amostra aos imóveis com andar declarado maior ou igual a um (5.106 registros) e, em seguida, àqueles com todas as variáveis do modelo preenchidas (5.051). Removeram-se os valores unitários atípicos por meio da cerca de Tukey aplicada ao logaritmo do valor por metro quadrado, o que delimitou a faixa admissível entre R\$ 2.395/m² e R\$ 37.624/m², e descartaram-se as coordenadas situadas fora do município, resultando em 5.025 registros. Aplicou-se, ainda, um limite de seis vagas de garagem, para conter contagens extremas de baixa frequência (5.020 registros), e excluíram-se quinze imóveis com andar superior a quarenta, identificados como erros de cadastro. A base final consolidou-se em **5.005 apartamentos**.

A variável resposta é o logaritmo natural do valor unitário — calculado pela razão entre o preço anunciado e a área privativa —, $\ln(V/m^2)$. As variáveis explicativas são o logaritmo da área privativa, o número de quartos, de banheiros e de vagas, e o andar. Para o TabPFN, acrescentaram-se a latitude e a longitude como atributos, dado que o método não dispõe de mecanismo espacial próprio; os modelos de regressão, ao contrário, capturam a localização pela matriz de vizinhança. A coincidência de coordenadas é esperada em apartamentos, pois unidades distintas de uma mesma edificação compartilham a localização. A base consolidada e os *scripts* em Python e R serão disponibilizados publicamente, em atenção aos princípios de reprodutibilidade e rastreabilidade preconizados pelas normas de avaliação.

3.2 Análise exploratória dos dados

A Tabela 1 apresenta as estatísticas descritivas das variáveis. O valor unitário mediano é de R\$ 9.238/m², com média de R\$ 10.541/m² e assimetria positiva (1,17), compatível com distribuição log-normal. A área privativa mediana é de 100 m² e o andar mediano, seis.

Tabela 1 — Estatísticas descritivas (n = 5.005)


Tabela 1						
Variável	Média	DP	Mín.	Mediana	Máx.	Assim.
valor unitário (R\$/m ²)	10.541	5.082	2.910	9.238	37.500	1,17
área privativa (m ²)	115,2	63,3	10	100	734	2,13
quartos	2,9	0,9	1	3	7	-0,17
banheiros	2,4	1,0	1	2	7	0,84
vagas	2,0	0,9	0	2	6	0,74
andar	7,9	5,4	1	6	35	1,12

Fonte: elaborado pelos Autores

Nota: DP = desvio-padrão; Assim. = assimetria.

A transformação logarítmica normaliza de forma satisfatória o valor unitário e a área, como ilustra a Fig. 3. A análise de Box e Cox (1964) indicou parâmetro $\lambda \approx -0,16$ para ambas as variáveis, próximo de zero, o que corrobora o uso do logaritmo.


Figura 2 — Localização dos 5.005 apartamentos, com o valor unitário em cor



Fonte: elaborado pelos Autores

A Fig. 2 evidencia o gradiente espacial do valor: os imóveis de maior valor unitário concentram-se na região Centro-Sul, ao passo que os vetores norte e oeste apresentam valores inferiores. Esse padrão sugere autocorrelação espacial, confirmada adiante.

Figura 3 — Valor unitário e área, nas escalas original e logarítmica




Fonte: elaborado pelos Autores

A matriz de correlação (Fig. 4) revela um aspecto central para a modelagem: as correlações das variáveis estruturais com o valor unitário são fracas ou negativas —


o logaritmo da área correlaciona-se a $-0,13$ e o número de quartos, a $-0,11$ —, ao passo que o andar apresenta a maior correlação individual ($+0,46$) e as coordenadas exibem correlações de mesma ordem (longitude $+0,21$; latitude $-0,21$). A correlação negativa entre quartos e valor unitário reflete o efeito de escala: apartamentos maiores, com mais quartos, situam-se com frequência fora das áreas mais valorizadas. Esse resultado reforça a hipótese de que a localização domina a formação do valor unitário e, por conseguinte, a pertinência dos tratamentos espaciais.

Figura 4 — Matriz de correlação de Pearson entre as variáveis



Fonte: elaborado pelos Autores

Figura 5 — Valor unitário segundo o andar (a) e a área privativa (b)



Fonte: elaborado pelos Autores

A Fig. 5 detalha as duas relações mais informativas. O valor unitário cresce de modo aproximadamente monotônico com o andar — o que antecipa a relevância desse atributo —, enquanto a relação com a área é difusa e levemente decrescente, coerente com a correlação observada.

3.3 Métodos e fundamentação matemática

Estimaram-se cinco modelos. Os três primeiros — OLS, SAR e SEM — foram ajustados com a biblioteca *spreg* do ecossistema *PySAL*, em Python; o SAR e o SEM por máxima verossimilhança. O PS-SAR foi ajustado com o pacote *pspatreg* em R (MÍNGUEZ; BASILE; DURBÁN, 2024), por máxima verossimilhança restrita. O TabPFN v3 foi executado a partir de seus pesos oficiais, em inferência sobre processador. As formulações de OLS, SAR, SEM e PS-SAR constam das Seções 2.1 a 2.3; o TabPFN, da Seção 2.4.

A matriz de vizinhança W adotada em todos os modelos espaciais e no cálculo do I de Moran é a dos oito vizinhos mais próximos (*k-nearest neighbors*, $k = 8$), padronizada por linha, de modo que cada linha some a unidade. Essa especificação garante que todo imóvel tenha exatamente oito vizinhos, evitando ilhas, e é usual em bases imobiliárias densas.

Na predição fora da amostra, o SAR combinou $X\beta$ com p vezes a média da resposta observada nos oito vizinhos de treinamento mais próximos. No SEM, como o termo espacial atua sobre o erro não observado, empregou-se $X\beta$ no conjunto de teste, sem extrapolar resíduos espaciais do treinamento.

Para o PS-SAR, adotaram-se funções *P-spline* para os atributos contínuos e de contagem e uma superfície geoaditiva bidimensional sobre as coordenadas. Como o pacote *pspatreg* não dispõe de rotina nativa de predição fora da amostra, a predição no conjunto de teste foi obtida de forma explícita, combinando o componente sistemático estimado — aproximado nos pontos de teste por média ponderada dos oito vizinhos mais próximos no espaço de atributos — e o termo de defasagem espacial $\rho W y$, calculado com a média da resposta dos oito vizinhos de treinamento. Essa aproximação preserva a comparabilidade com o SAR, que emprega procedimento equivalente para o termo espacial fora da amostra.

3.4 Validação cruzada espacial e métricas

A avaliação de modelos em dados espaciais requer cautela: a reamostragem aleatória tende a distribuir observações vizinhas simultaneamente entre treino e teste, o que, dada a autocorrelação, produz otimismo nas métricas. Adotou-se, por isso, validação cruzada por blocos espaciais: as coordenadas foram agrupadas por *K-means* em dez agrupamentos contíguos, com tamanhos entre 199 e 919 imóveis, e cada agrupamento serviu, alternadamente, como conjunto de teste, sendo os demais o conjunto de treinamento. Todas as métricas foram computadas exclusivamente sobre as predições fora da amostra, reunidas ao final para os 5.005 imóveis. Essa agregação atribui o mesmo peso a cada imóvel, e não o mesmo peso a cada bloco.

Quatro métricas foram consideradas. A raiz do erro quadrático médio (RMSE) e o erro absoluto médio (MAE) foram computados na escala logarítmica da resposta. O erro percentual absoluto médio (MAPE) foi computado na escala monetária, após a exponenciação, por ser a medida de maior interpretabilidade para o avaliador. O coeficiente de determinação (R^2) foi calculado na escala logarítmica. Reporta-se, ainda, o I de Moran dos resíduos fora da amostra, indicador da parcela de estrutura espacial não capturada por cada modelo. A significância das diferenças de erro absoluto entre modelos foi aferida pelo teste não paramétrico de Wilcoxon pareado (WILCOXON, 1945), apropriado por não exigir normalidade das diferenças.

4. Resultados e discussão

4.1 Diagnóstico de dependência espacial

O ajuste do OLS sobre a base completa confirmou a pertinência do tratamento espacial. A variável resposta apresentou I de Moran de 0,476, altamente significativo ($z = 73,5$; $p < 0,001$), o que indica forte agrupamento espacial dos valores. Nos resíduos do OLS ajustado sobre a base completa, o I de Moran foi de 0,432 ($p < 0,001$); esse diagnóstico em amostra difere do valor de 0,476 reportado na Tabela 2, calculado sobre resíduos fora da amostra. Os testes de multiplicadores de Lagrange rejeitaram a ausência de dependência tanto na defasagem quanto no erro, com as versões robustas igualmente significativas (todas com $p < 0,001$). Os coeficientes do OLS mostraram-se coerentes com a teoria: o andar apresentou efeito positivo de aproximadamente 3,1% por pavimento sobre o valor unitário, e o número de vagas e de banheiros contribuiu positivamente, ao passo que o logaritmo da área exibiu sinal negativo, capturando o efeito de escala já discutido. Esses diagnósticos justificam a adoção dos modelos SAR, SEM e PS-SAR.

4.2 Desempenho comparativo

A Tabela 2 sintetiza o desempenho fora da amostra das cinco abordagens.

Tabela 2 — Desempenho comparativo dos modelos (base 5.005, validação cruzada espacial).

Tabela 2					
Modelo	RMSE (log)	MAE (log)	MAPE (%)	R ² (log)	I de Moran dos resíduos
OLS — mínimos quadrados ordinários	0,354	0,285	28,8	0,403	0,476
SAR — defasagem espacial	0,341	0,267	27,8	0,445	0,478
SEM — erro espacial	0,368	0,298	29,7	0,356	0,564
PS-SAR — espacial semiparamétrico	0,354	0,281	32,9	0,402	0,397
TabPFN v3 — modelo de fundação	0,312	0,242	24,4	0,538	0,393

Fonte: elaborado pelos Autores

O TabPFN v3 obteve o melhor resultado em todas as métricas de acurácia, com R² de 0,538, MAPE de 24,4% e RMSE de 0,312 na escala logarítmica. Entre os modelos espaciais lineares, o SAR foi o melhor (R² = 0,445), superando o OLS (0,403) e confirmando o ganho do tratamento por defasagem espacial; o SEM apresentou o pior desempenho preditivo (R² = 0,356), a despeito de ajustar-se bem à estrutura de erro. O coeficiente autorregressivo médio do SAR situou-se em torno de 0,60, sinalizando dependência espacial substancial.


O PS-SAR merece leitura cuidadosa. Seu desempenho preditivo equiparou-se ao do OLS (R² = 0,402) e ficou aquém do SAR, resultado à primeira vista contraintuitivo para um modelo mais flexível. A explicação reside em dois fatores. Primeiro, a superfície geoaditiva do PS-SAR absorveu grande parte da estrutura espacial, o que se reflete no menor coeficiente autorregressivo (cerca de 0,42, ante 0,60 do SAR) e, sobretudo, no baixo I de Moran dos resíduos (0,397). Ou seja, o modelo capturou bem a dependência espacial em amostra. Segundo, esse ajuste não se converteu em vantagem preditiva fora da amostra, em razão da limitação de predição do pacote

pspatreg, que não dispõe de rotina nativa para novos pontos e exige a aproximação descrita na Seção 3.3 — penalidade que se manifesta no MAPE mais alto (32,9%). Trata-se, portanto, de limitação operacional do procedimento de predição, e não de deficiência do modelo em capturar a estrutura dos dados.

4.3 Valores previstos versus observados e análise de resíduos

A Fig. 6 confronta os valores previstos e observados de cada modelo, com a bissetriz destacada em vermelho. A maior aderência à bissetriz e a menor dispersão dos pontos do TabPFN v3, em comparação com os demais, corroboram as métricas da Tabela 2. Os modelos OLS e SEM exibem nuvem mais dispersa; o SAR e o PS-SAR, intermediária; o TabPFN v3, a mais concentrada.


Figura 6 — Valores previstos versus observados, por método (ln do valor unitário; predições fora da amostra)



Fonte: elaborado pelos Autores


A Fig. 7 apresenta os resíduos em função dos valores previstos. Em todos os modelos, os resíduos distribuem-se em torno de zero sem tendência acentuada, o que sustenta a adequação das especificações. A menor amplitude da nuvem de resíduos do TabPFN v3 (desvio-padrão de 0,311) é visível, seguida do PS-SAR (0,326) e do SAR (0,341). A Fig. 8 complementa a análise com os histogramas dos resíduos e a curva normal ajustada, evidenciando distribuições aproximadamente simétricas e centradas na origem, com leve excesso de curtose — padrão usual em dados imobiliários.

Figura 7 — Resíduos versus valores previstos, por método (predições fora da amostra)



Fonte: elaborado pelos Autores

Figura 8 — Distribuição dos resíduos por método, com curva normal ajustada



Fonte: elaborado pelos Autores

4.4 Autocorrelação espacial dos resíduos

O I de Moran dos resíduos (última coluna da Tabela 2) oferece uma leitura reveladora. Os modelos OLS, SAR e SEM mantiveram autocorrelação residual elevada (entre 0,476 e 0,564): a defasagem espacial do SAR melhora a predição, mas não elimina a estrutura espacial dos resíduos, e o SEM, curiosamente, apresenta o maior valor. Em contraste, o PS-SAR (0,397) e o TabPFN v3 (0,393) reduziram substancialmente a autocorrelação residual. No caso do PS-SAR, isso decorre da superfície geoaditiva explícita; no caso do TabPFN v3, o resultado é notável, pois o modelo não incorpora mecanismo espacial algum — apenas as coordenadas como atributos. Os resultados sugerem que a flexibilidade não linear do TabPFN representou parte do gradiente espacial do valor a partir da latitude e da longitude e reduziu a dependência residual que os modelos lineares tratam por construção explícita.

4.5 Testes de significância

O teste de Wilcoxon pareado sobre os erros absolutos indicou diferenças sob o protocolo adotado. O TabPFN v3 apresentou erros absolutos menores que os de todos os concorrentes no teste aplicado ($p < 0,001$ em todas as comparações: contra SAR, OLS, SEM e PS-SAR). Entre os modelos espaciais, o SAR superou o PS-SAR de forma significativa ($p < 0,001$), coerente com a Tabela 2, ao passo que o PS-SAR superou marginalmente o OLS ($p = 0,028$). A Tabela 3 resume as comparações de maior interesse.

Tabela 3 — Teste de Wilcoxon pareado dos erros absolutos (seleção de comparações).

Tabela 3				
Comparação	Mediana $ e $ (1°)	Mediana $ e $ (2°)	p-valor	Modelo superior
TabPFN v3 vs SAR	0,196	0,220	$< 0,001$	TabPFN v3
TabPFN v3 vs PS-SAR	0,196	0,236	$< 0,001$	TabPFN v3
TabPFN v3 vs OLS	0,196	0,248	$< 0,001$	TabPFN v3
SAR vs PS-SAR	0,220	0,236	$< 0,001$	SAR
PS-SAR vs OLS	0,236	0,248	0,028	PS-SAR

Fonte: elaborado pelos Autores

4.6 Discussão

Os resultados respondem às três perguntas de pesquisa. Quanto à primeira, o tratamento espacial explícito por defasagem (SAR) melhora a predição fora da amostra em relação ao OLS, confirmando o benefício reconhecido na literatura brasileira (BILYK; RIBEIRO; CORRÊA, 2020); o tratamento por erro (SEM), contudo, não trouxe ganho preditivo neste conjunto. Quanto à segunda, a flexibilização não linear do modelo espacial (PS-SAR) não se traduziu em ganho preditivo fora da amostra, embora tenha reduzido de forma expressiva a autocorrelação residual — um resultado que separa nitidamente a qualidade do ajuste em amostra da capacidade de generalização, e que aponta a predição fora da amostra em modelos semiparamétricos como problema metodológico a merecer atenção. Quanto à terceira, e principal, sob o protocolo adotado, o TabPFN v3 — método não linear de uso direto, sem modelagem espacial explícita — apresentou o melhor desempenho e diferenças estatisticamente significativas em relação às abordagens espaciais no teste aplicado.

Esse achado dialoga com a literatura recente que documenta a incorporação de informação espacial em modelos tabulares por meio de atributos, sem estrutura de vizinhança explícita (SCHMIDINGER *et al.*, 2025), e com a evidência de que modelos de fundação tabulares competem com métodos especializados em domínios diversos (HOLLMANN *et al.*, 2025). Do ponto de vista da avaliação em massa, o resultado é atraente: o TabPFN dispensa busca de hiperparâmetros e ajuste iterativo, produz predições em uma única passada e, sob o protocolo adotado, representou parte do gradiente espacial do valor. Cabe ressaltar, todavia, que a menor autocorrelação residual não equivale a interpretabilidade: diferentemente do SAR e do PS-SAR, cujos coeficientes e superfícies são inspecionáveis, o TabPFN opera como caixa-preta, o que impõe cautela quanto à exigência normativa de fundamentação (ABNT, 2011) e recomenda o uso de técnicas de interpretabilidade em trabalhos futuros. Neste estudo, não foram calculadas atribuições SHAP; sua aplicação permitiria decompor as predições por atributo, desde que interpretada como explicação associativa do modelo, e não como evidência causal (LUNDBERG; LEE, 2017).

4.7 Limitações

O estudo apresenta limitações que delimitam o alcance das conclusões. **(i)** a base compõe-se de dados de oferta, e não de transação, o que pode introduzir viés de preço pedido; **(ii)** o conjunto de atributos é enxuto: a ausência de variáveis de padrão construtivo, idade e amenidades urbanas de entorno tende a limitar o teto de acurácia de todos os modelos e a inflar a importância relativa da localização; **(iii)** a predição fora da amostra do PS-SAR apoia-se em aproximação, por limitação do pacote, o que penaliza seu desempenho e recomenda prudência na comparação direta com o SAR. **(iv)** o desempenho do TabPFN foi avaliado com o protocolo de duas passadas e média de sementes; a repetição com múltiplas configurações e o reporte de intervalos de confiança fortaleceriam a ordenação. Reconhecem-se, ainda, o recorte a uma única cidade e tipologia e a natureza de caixa-preta do método vencedor, aspectos a serem endereçados em investigações subsequentes. Por fim, o *Wilcoxon* foi aplicado às perdas individuais fora da amostra; como observações espacialmente próximas — inclusive unidades de uma mesma edificação — podem não ser independentes, os valores de *p* devem ser lidos como evidência complementar do protocolo, e não como inferência baseada em blocos independentes

5. Conclusões

Este trabalho comparou cinco abordagens de modelagem do valor unitário de apartamentos em Belo Horizonte — OLS, SAR, SEM, PS-SAR e TabPFN v3 — sob validação cruzada por blocos espaciais, sobre uma base única de 5.005 imóveis. Observou-se forte dependência espacial na variável resposta e nos resíduos do OLS, o que justifica os tratamentos espaciais. Entre os modelos espaciais lineares, o SAR foi o de melhor desempenho preditivo, superando o OLS; o modelo semiparamétrico PS-SAR, embora tenha reduzido de forma acentuada a autocorrelação residual, não superou o SAR fora da amostra, em razão de limitação do procedimento de predição.

Sob o protocolo adotado, o principal achado é que o TabPFN v3, método não linear de uso direto e sem modelagem espacial explícita, obteve o melhor desempenho em todas as métricas e apresentou diferenças estatisticamente significativas em relação às abordagens espaciais tradicionais no teste aplicado, além de reduzir a autocorrelação dos resíduos a patamar comparável ao do PS-SAR. O resultado sugere que modelos de fundação para dados tabulares podem representar o gradiente espacial do valor a partir das coordenadas e constituir alternativa promissora para a avaliação em massa. Recomendam-se, como desdobramentos, a incorporação de atributos de padrão e de entorno, a repetição com múltiplas sementes e intervalos de confiança, a validação em outras cidades e tipologias e a aplicação de técnicas de interpretabilidade que compatibilizem a acurácia do método com a exigência normativa de fundamentação.

Nota metodológica sobre o uso de inteligência artificial

Os experimentos de regressão espacial e de aprendizado de máquina foram conduzidos em *Python* (bibliotecas *sprege*, *libpysal* e *esda*) e em *R* (pacote *pspatreg*). O modelo TabPFN foi executado a partir de seus pesos oficiais, sob licença não comercial. Ferramentas de inteligência artificial foram empregadas como apoio à organização do *pipeline* de análise, à geração de figuras e à edição do texto, sob revisão e responsabilidade integral dos autores. A base de dados e os *scripts* serão disponibilizados publicamente, em atenção aos princípios de reprodutibilidade e rastreabilidade.

6. Referências

- ANSELIN, L. **Spatial econometrics**: methods and models. Dordrecht: Kluwer Academic Publishers, 1988.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14653-1**: avaliação de bens — Parte 1: procedimentos gerais. Rio de Janeiro: ABNT, 2019.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14653-2**: avaliação de bens — Parte 2: imóveis urbanos. Rio de Janeiro: ABNT, 2011.
- BILYK, B.; RIBEIRO, C. G.; CORRÊA, R. Índice de preços hedônicos para apartamentos: aplicação a dados fiscais de Belo Horizonte, 1995–2012. **Economia e Sociedade**, Campinas, v. 29, n. 1, p. 305–330, 2020.
- BOX, G. E. P.; COX, D. R. An analysis of transformations. **Journal of the Royal Statistical Society: Series B**, London, v. 26, n. 2, p. 211–252, 1964.

EILERS, P. H. C.; MARX, B. D. Flexible smoothing with B-splines and penalties. **Statistical Science**, Hayward, v. 11, n. 2, p. 89–121, 1996.

GREENE, W. H. **Econometric analysis**. 8. ed. Nova York: Pearson Education, 2018.

GRINSZTAJN, L. *et al.* TabPFN-3: technical report. *arXiv*, 2026. Disponível em: <https://arxiv.org/abs/2605.13986>. Acesso em: 29 ago. 2026.

GYGER, S. Explainable spatial *machine learning* for hedonic real estate modeling. **Real Estate Economics**, [s. l.], 2025. DOI: <https://doi.org/10.1111/1540-6229.70030>.

HOLLMANN, N. *et al.* Accurate predictions on small data with a tabular *foundation model*. **Nature**, London, v. 637, p. 319–326, 2025. DOI: <https://doi.org/10.1038/s41586-024-08328-6>.

LESAGE, J.; PACE, R. K. **Introduction to spatial econometrics**. Boca Raton: CRC Press, 2009.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017. *Anais [...]*. [S. l.]: Curran Associates, 2017. p. 4765–4774. Disponível em: <https://arxiv.org/abs/1705.07874>. Acesso em: 29 ago. 2026.

MALPEZZI, S. Hedonic pricing models: a selective and applied review. In: O'SULLIVAN, T.; GIBB, K. (org.). **Housing economics and public policy**. Oxford: Blackwell, 2003. p. 67–89.

MÍNGUEZ, R.; BASILE, R.; DURBÁN, M. An alternative semiparametric model for spatial panel data. **Statistical Methods & Applications**, Berlin, v. 29, n. 4, p. 669–708, 2020. DOI: <https://doi.org/10.1007/s10260-019-00492-8>.

MÍNGUEZ, R.; BASILE, R.; DURBÁN, M. *pspatreg*: R package for semiparametric spatial autoregressive models. **Mathematics**, Basel, v. 12, n. 22, artigo 3598, 2024. DOI: <https://doi.org/10.3390/math12223598>.

MORAN, P. A. P. Notes on continuous stochastic phenomena. **Biometrika**, London, v. 37, n. 1-2, p. 17–23, 1950.

MURA, F.; CONTRERAS, D. Comparing automated valuation models for real estate assessment in the Santiago Metropolitan Region: *machine learning* algorithms and hedonic pricing with spatial adjustments. **PLOS ONE**, San Francisco, v. 20, n. 2, artigo e0318701, 2025. DOI: <https://doi.org/10.1371/journal.pone.0318701>.

ROSEN, S. Hedonic prices and implicit markets: product differentiation in pure competition. **Journal of Political Economy**, Chicago, v. 82, n. 1, p. 34–55, 1974.

SCHMIDINGER, J. *et al.* Kriging prior regression: a case for kriging-based spatial features with TabPFN in soil mapping. *arXiv*, 2025. DOI: <https://doi.org/10.48550/arXiv.2509.09408>. Disponível em: <https://arxiv.org/abs/2509.09408>. Acesso em: 29 jul. 2026.

TOBLER, W. R. A computer movie simulating urban growth in the Detroit region. **Economic Geography**, [s. l.], v. 46, p. 234–240, 1970.

WILCOXON, F. Individual comparisons by ranking methods. **Biometrics Bulletin**, [s. l.], v. 1, n. 6, p. 80–83, 1945.